

RCNN, YOLO 정리

24기 정현서

RCNN

기존 객체 탐지 방식(R-CNN, Fast R-CNN)은 먼저 후보 영역(Region Proposal)을 생성한 후 각 영역을 분류하는 방식으로 진행됨.

• **문제점:**

R-CNN은 후보 영역마다 CNN을 반복 실행하여 속도가 매우 느렸고, Fast R-CNN도 후보 영역 생성 단계(Selective Search 등)에서 병목 현상이 발생함.

Faster R-CNN의 핵심 아이디어

Region Proposal Network (RPN) 도입:

- CNN의 Feature Map에서 슬라이딩 윈도우 방식으로 후보 영역(Anchors)을 생성
- 각 슬라이딩 윈도우에서 고정된 수의 앵커(예, 3개 스케일과 3개 비율 → 총 9개)를 사용하여 객체 여부 및 위치를 예측

공유된 합성곱 계층:

RPN과 Fast R-CNN이 동일한 합성곱 계층을 공유하여 전체 네트워크를 하나로 통합, 연산 효율을 극대화함.

• **ROI Pooling:**

전체 이미지의 Feature Map에서 후보 영역에 해당하는 부분을 고정된 크기로 변환해 FC 계층에 입력

• **Loss Function:**

- **분류 손실:** 이진 교차 엔트로피를 사용하여 객체와 배경을 구분
- **회귀 손실:** Smooth L1 Loss를 사용해 예측한 바운딩 박스 좌표와 실제 좌표의 차이를 줄임
- **Anchors 설정 및 NMS:**

다양한 크기와 비율을 고려한 앵커를 사용하며, 테스트 시 Non-Maximum Suppression(NMS)을 통해 중복 영역 제거

- **학습 방식:**

4단계의 alternating training(교대로 학습) 방식으로 RPN과 Fast R-CNN을 순차적으로 학습한 후, 공통된 합성곱 계층을 공유

- **실험:**

- PASCAL VOC와 MS COCO 데이터셋에서 높은 mAP 성능을 기록
- RPN 도입으로 제안 영역 수가 대폭 줄어들었음에도 불구하고, 기존 방법(Selective Search 등)보다 높은 정확도와 빠른 처리 속도를 보임
- Ablation study를 통해 각 구성 요소(분류, 회귀, 앵커 설정 등)의 중요성을 검증

- **효율성과 속도:**

RPN과 Fast R-CNN의 통합으로 객체 탐지의 병목을 제거하여 거의 실시간 처리가 가능해짐

- **정확도 향상:**

공유된 합성곱 계층과 효율적인 후보 영역 생성 기법 덕분에 기존 방법보다 높은 정확도를 달성

YOLO

기존 탐지 방식과 YOLO의 차별점

- **기존 탐지 방식:**

- 이미지에서 먼저 특징(feature)을 추출한 후, 분류기(Classifier)나 위치 예측기(Localizer)를 별도로 적용
- 슬라이딩 윈도우나 후보 영역(Region Proposal) 방식을 사용하여 여러 단계를 거치며 복잡한 파이프라인을 구성

- **YOLO의 접근법:**

- 단일 통합 네트워크를 사용하여 $S \times S$ 그리드 기반 예측으로 바로 객체 탐지 수행
- 후보 영역 생성 없이 한 번의 전파로 bounding box와 클래스 예측을 동시에 진행
- end-to-end 학습이 가능하여 구조가 단순하고 연산 효율이 높음

• YOLO vs R-CNN:

- R-CNN은 region proposal 생성, CNN 처리, SVM 분류, 박스 보정 등 여러 단계로 이루어져 복잡함
- YOLO는 전체 네트워크가 하나로 통합되어 있어 간결하고 빠름

• YOLO vs DPM:

- YOLO는 단일 네트워크로 구조가 단순하며, 연산 효율이 뛰어남

• YOLO vs Fast/Faster R-CNN, MultiBox, OverFeat:

- Fast/Faster R-CNN은 region proposal 과정이 존재하여 상대적으로 느림
- MultiBox는 박스 예측에 한정되고, OverFeat는 위치 중심으로 전역 문맥 반영에 한계가 있음
- YOLO는 bounding box와 클래스 예측을 동시에 처리하여 전체 시스템의 복잡성을 크게 줄임

실험 및 성능 분석

• 성능 비교:

- YOLO는 매우 빠른 처리 속도를 보이며, 실시간 탐지에 적합한 모델임
- 단, 위치(localization) 예측에서는 다소 부정확한 부분이 있으나, 객체 존재 여부는 잘 맞춤
- Fast R-CNN은 배경을 객체로 잘못 탐지하는 오류가 있음
- 두 모델은 서로 다른 오류 유형을 보여주어, 상호 보완이 가능함

• 응용 사례:

- 자율주행, 드론 등 실제 환경에서 실시간 객체 탐지가 요구되는 상황에 매우 유용함

YOLO의 핵심 및 중요성

• 핵심 포인트:

1. 기존 복잡한 탐지 파이프라인을 제거하고 단일 CNN으로 통합
2. end-to-end 학습이 가능해 설계와 구현이 간단함
3. 속도와 구조적 단순성 덕분에 실시간 응용에 적합
4. 다른 모델의 한계를 보완할 수 있는 강점을 가짐

• 결론:

YOLO는 간결하고 빠르며, 실제 응용 환경에서 뛰어난 성능을 발휘하는 객체 탐지 모델로, 앞으로 다양한 분야에 응용될 가능성이 높음