

1. 서론 (Introduction)

배경: NLP에서는 거대 언어 모델이 텍스트 기반 프롬프트를 통해 새로운 작업에 zero-shot 으로 일반화하는 능력을 보임. 비슷한 개념을 컴퓨터 비전에서도 적용하려는 시도.

목표: 이미지 세분화를 위한 프롬프트 기반(foundation-level) 모델을 만들고자 함.

핵심 요소:

프롬프트 가능한 세분화 작업 (promptable segmentation task)

세분화 모델 SAM

대규모 데이터 수집 엔진 및 데이터셋 SA-1B

2. 세분화 작업 정의 (Segment Anything Task)

프롬프트 기반 세분화란?

프롬프트(예: 점, 박스, 텍스트 등)를 입력하면, 해당 객체에 대한 마스크를 반환.

애매한 프롬프트에도 유효한 마스크를 출력해야 함.

학습 방식:

다양한 프롬프트(점, 박스, 마스크 등)를 시뮬레이션하여 마스크 예측 → GT 마스크와 비교하며 학습.

Ambiguity(모호성)를 수용할 수 있도록 설계됨.

Zero-shot transfer:

사전 학습된 모델이 새로운 작업에도 프롬프트만 주어진다면 대응 가능.

다양한 실제 응용 작업들을 프롬프트 구성만으로 해결 가능.

3. Segment Anything Model (SAM)

구성 요소:

이미지 인코더:

ViT 기반, 이미지 임베딩 생성.

프롬프트 인코더:

점, 박스, 마스크는 위치 임베딩 + 유형 임베딩.

텍스트 프롬프트는 CLIP 텍스트 인코더 사용.

마스크 디코더:

Transformer 디코더 블록 기반.

입력 임베딩 + 프롬프트로 마스크 예측.

다중 마스크 출력 가능 → 애매한 입력 대응.

속도: 이미지 임베딩만 미리 계산되면, 프롬프트 처리와 마스크 예측은 50ms 내외로 가능.

4. 데이터 엔진 (Data Engine)

총 3단계로 구성된 마스크 수집 과정:

보조 수동 단계:

초기에는 사람이 직접 마스크 수동 작업.

SAM이 마스크 생성을 도와주는 브라우저 기반 툴 사용.

반자동 단계:

SAM이 자신감 높은 객체를 먼저 자동 생성 → 사람이 나머지 객체 보완.

완전 자동 단계:

32x32 점 그리드로 자동 프롬프트 입력 → SAM이 다양한 마스크 생성.

안정성 및 중복 필터링(NMS)을 통해 최종 마스크 선별.

5. 데이터셋 SA-1B

구성:

11M 장의 고해상도 이미지 (평균 3300x4950px)

1.1B 개의 마스크 (평균 약 100개/이미지)

품질:

자동 마스크 vs 전문가 수정 마스크 비교 시, 94%가 IoU 90% 이상.

다양한 크기, 모양, 지역에 걸쳐 존재.

다른 데이터셋(COCO, LVIS 등)보다 훨씬 많은 수의 마스크 제공.

6. Responsible AI 분석

지리적/소득별 분포:

전 세계 다양한 지역 커버 (유럽 및 아시아 중심)

모든 대륙에 최소 수십만 개의 마스크 존재

공정성 평가:

젠더, 연령, 피부톤 기준으로 SAM의 성능을 분석

성능 차이가 거의 없었으며, 대부분의 그룹 간 격차가 통계적으로 유의미하지 않음

7. Zero-shot Transfer 실험

SAM은 훈련에 쓰이지 않은 작업들에 대해서도 프롬프트만으로 높은 성능을 보임.

작업들:

단일 포인트 → 마스크

엣지 감지

객체 제안

인스턴스 세분화

텍스트 → 마스크

결과:

23개 데이터셋에서 RITM 등 기존 방법보다 우수한 성능

자동 평가보다 사람 평가에서 SAM 마스크 품질이 더 높게 나옴

8. 종합 및 한계

장점:

다양한 작업에 zero-shot으로 대응 가능

고속 반응

대규모 고품질 데이터 기반

한계:

정밀한 구조나 세밀한 경계에서는 성능 열세

실시간 처리 전체 파이프라인 측면에서는 무거운 이미지 인코더의 영향 있음

텍스트 프롬프트에 대한 예측은 아직 실험적