



SAM

Segment Anything

저자 : Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C. Berg, Wan-Yen Lo, Piotr Dollár, Ross Girshick

Segment Anything

We introduce the Segment Anything (SA) project: a new task, model, and dataset for image segmentation. Using our efficient model in a data collection loop, we built the largest

 <https://arxiv.org/abs/2304.02643>



1. Introduction

- SAM(Segment Anything Model)은 promptable segmentation을 제안한 모델로, 처음 보는 이미지나 객체에 대해 실시간으로 세분화된 마스크를 제공하는 foundation model
- NLP의 GPT처럼, 컴퓨터 비전에서도 제로샷으로 범용적 적용이 가능한 모델을 만들고자 함
- 이 모델을 구현하기 위해 세 가지 핵심 구성 요소를 제시
 1. **Task**: Promptable segmentation
 2. **Model**: Segment Anything Model (SAM)
 3. **Data**: 대규모 데이터셋 SA-1B (11M 이미지, 1B 마스크)

→ 이 세 가지를 통합하여 **새로운 세그멘테이션 패러다임**을 제안하였습니다.

2. Segment Anything Task




Figure 3: Each column shows 3 valid masks generated by SAM from a single ambiguous point prompt (green circle).

Segment Anything Task는 사용자가 주는 다양한 형태의 프롬프트 (점, 박스, 마스크, 텍스트 등)를 입력으로 받아 유효한 segmentation mask를 반환하는 과제

- 복잡하거나 모호한 상황에서도 유효한 마스크를 생성해야 함
- NLP의 prompt 개념을 차용하여 다양한 segmentation task에 zero-shot 적용 가능
- 예: 셔츠 위의 점 하나가 사람 전체일 수도, 셔츠일 수도 있음 → 둘 다 유효한 결과


→ 다양한 task를 프롬프트 조합만으로 해결 가능하게 함

3. Segment Anything Model




SAM은 다음의 세 모듈로 구성된 구조:

- Image Encoder: MAE 기반 ViT 사용
 - 이미지 전체를 고해상도로 임베딩 (재사용 가능)



- Prompt Encoder:
 - 점/박스 → 위치 + 프롬프트 타입 인코딩
 - 텍스트 → CLIP text encoder 사용
 - 마스크 → ConvNet 기반 dense embedding
- Mask Decoder:
 - Transformer 구조 기반으로 cross-attention 수행
 - Prompt + Image embedding → 여러 개의 마스크 출력 (보통 3개)

- 각 마스크에 confidence score도 포함 (IoU 추정)



⇒ 브라우저에서도 50ms 내 마스크 생성 가능 → 실시간 상호작용 가능

4. Segment Anything Data Engine

A-1B 데이터셋은 다음 세 가지 단계의 데이터 엔진을 통해 구축됨:

1. Assisted-manual: 사람이 SAM 도움 받아 포인트 클릭 + 편집
 - 12만 이미지, 430만 마스크 수집
2. Semi-automatic: SAM이 일부 객체 자동 분할 → 나머지는 사람
 - 18만 이미지, 590만 마스크 추가
3. Fully-automatic: 모든 이미지를 SAM이 자동 분할 (32x32 grid, zoom crop 등 적용)
 - 최종 1.1B 마스크 생성

5. Segment Anything Dataset




Figure 6: Dataset mask properties. The legend references the number of images and masks in each dataset. Note, that SA-1B has $11\times$ more images and $400\times$ more masks than the largest existing segmentation dataset Open Images [60].

- 11M 장의 고해상도 이미지 + 1.1B 개의 마스크

- 모든 이미지: 저작권 확보 + 개인 식별 정보 블러 처리
- 평균 이미지당 100개 이상의 마스크
- 무작위 500장 평가 결과: 94%가 IoU 90% 이상
- 다양한 크기, 모양, 지역 포함 → 높은 대표성

6. Segment Anything RAI Analysis




Figure 7: Estimated geographic distribution of SA-1B images. Most of the world's countries have more than 1000 images in SA-1B, and the three countries with the most images are from different parts of the world.


공정성 평가

- 성별, 연령, 피부톤 그룹별로 mIoU 비교 → 성능 격차 거의 없음
- 일부 저소득 지역(아프리카 등)은 상대적으로 적은 비중 → 개선 여지
- MIAP 데이터셋 기준 평가 수행

7. Zero-Shot Transfer Experiments

SAM은 학습 없이도 다양한 task에서 우수한 성능을 보임

7.1. Zero-Shot Single Point Valid Mask Evaluation



- 단일 포인트를 프롬프트로 입력해 유효한 마스크를 생성하는 태스크
- 총 23개 벤치마크 데이터셋 사용 (예: GrabCut, FSS, COCO 등)
- SAM은 기존 모델인 RITM보다 대부분에서 높은 mIoU 기록
- 사용자 평가(human rating) 결과에서도 SAM이 더 자연스럽고 품질 높은 마스크 생성
- "Oracle evaluation" 방식(3개 마스크 중 가장 좋은 것 선택 기준)에서는 모든 벤치마크에서 RITM을 능가함

7.2. Zero-Shot Edge Detection



Figure 10: Zero-shot edge prediction on BSDS500. SAM was not trained to predict edge maps nor did it have access to BSDS images or annotations during training.

- SAM으로 생성한 마스크 → Sobel edge filter 적용 → 경계선 추출
- BSDS500 벤치마크에서 SAM은 기존 edge detector (HED 등)과 유사한 품질의 edge map 생성

- 학습 없이도 에지 검출이 가능하다는 것을 보여줌

7.3. Zero-Shot Object Proposals

method	all	mask AR@1000					
		small	med.	large	freq.	com.	rare
ViTDet-H [62]	63.0	51.7	80.8	87.0	63.1	63.3	58.3
<i>zero-shot transfer methods:</i>							
SAM – single out.	54.9	42.8	76.7	74.4	54.7	59.8	62.0
SAM	59.3	45.5	81.6	86.9	59.1	63.9	65.8

Table 4: Object proposal generation on LVIS v1. SAM is applied zero-shot, *i.e.* it was not trained for object proposal generation nor did it access LVIS images or annotations.

- SAM 마스크를 object proposal로 간주하여 평가 (즉, 어떤 객체가 있을 수 있는지 제안)
- LVIS 데이터셋 기준으로 평가
- 특히 중형~대형 객체나 희귀 클래스 객체에 대해 기존 object proposal 방식(ViTDet 등) 보다 높은 recall 보임
- 평균적으로 Top-1000 proposal 중 더 다양한 객체를 포착함

7.4. Zero-Shot Instance Segmentation

method	COCO [66]				LVIS v1 [44]			
	AP	AP ^S	AP ^M	AP ^L	AP	AP ^S	AP ^M	AP ^L
ViTDet-H [62]	51.0	32.0	54.3	68.9	46.6	35.0	58.0	66.3
<i>zero-shot transfer methods (segmentation module only):</i>								
SAM	46.5	30.8	51.0	61.7	44.7	32.5	57.6	65.5

Table 5: Instance segmentation results. SAM is prompted with ViTDet boxes to do zero-shot segmentation. The fully-supervised ViTDet outperforms SAM, but the gap shrinks on the higher-quality LVIS masks. Interestingly, SAM outperforms ViTDet according to human ratings (see Fig. 11).

- ViTDet의 bounding box를 SAM에 프롬프트로 제공 → 마스크 생성
- COCO/LVIS 데이터셋에서 평가

- Box 기반 AP는 ViTDet보다 낮지만, 사람 평가 기준으로는 SAM이 더 자연스럽고 매끄러운 마스크 생성
- 예: 옷의 주름까지 자연스럽게 포착하는 등 세밀한 분할 가능

7.5. Zero-Shot Text-to-Mask





Figure 12: Zero-shot text-to-mask. SAM can work with simple and nuanced text prompts. When SAM fails to make a correct prediction, an additional point prompt can help.

- CLIP의 텍스트 임베딩을 SAM에 prompt로 입력해 객체 마스크 생성
- 예: "a wheel", "a bird's wing", "a face" 등의 텍스트만으로도 유의미한 마스크 출력 가능
- 텍스트만으로는 다소 불안정한 결과도 있으나, 포인트 프롬프트와 결합하면 품질 개선 가능

7.6. Ablations



- 데이터 양: 전체 11M 이미지 대신 1M만 써도 좋은 성능 유지됨
- 수집 단계 비교: 수작업 없이 자동 생성된 마스크만으로도 90% 이상의 성능 확보
- 모델 스케일: ViT-B → ViT-L → ViT-H로 갈수록 성능은 개선되지만, ViT-L 이후 성능 향상은 점차 감소

8. Discussion

- Segment Anything은 segmentation의 GPT 같은 역할을 목표로 함
- prompt 기반이라 다양한 task에 조합 적용 가능
- CLIP처럼 다른 시스템과 결합해 응용 가능 (예: 3D 모델링, gaze 추적 등)

한계점:

- 작은 객체, 복잡한 구조에는 한계
- semantic/panoptic segmentation에는 더 복잡한 프롬프트 필요
- text-to-mask는 아직 발전 초기 단계

→ 그럼에도 불구하고, SAM은 세분화 분야에서 새로운 paradigm을 제시함