

SAM 논문 리뷰

1. 연구 배경 및 동기

- *이미지 분할(Image Segmentation)**은 컴퓨터 비전에서 핵심적인 과제 중 하나로, 객체 탐지, 인스턴스 분할, 시맨틱 분할 등의 다양한 형태로 발전해왔다. 하지만 대부분의 기존 세그멘테이션 모델은 **도메인 특화**되어 있어 새로운 데이터셋이나 태스크마다 다시 학습을 해야 하는 단점이 존재했다.

이에 대해 Meta AI는 **모든 객체를 분할할 수 있는 범용 모델**, 즉 *****"Segment Anything Model (SAM)"****을 제안하였다. 이 모델은 다양한 형태의 사용자 프롬프트(Point, Box, Mask)를 입력으로 받아 거의 ****제로샷(Zero-Shot)****으로 객체의 픽셀 단위 마스크를 생성할 수 있다.

2. 논문 주요 기여

1. 범용 분할 모델(**Segment Anything Model**) 개발
2. **100억 개 이상의 마스크**를 포함하는 초대규모 데이터셋 **SA-1B** 구축
3. **Zero-shot 전이 성능**이 우수한 범용 분할 모델 제공
4. 새로운 세그멘테이션 프레임워크: **프롬프트 기반 분할(Promptable Segmentation)** 제안

3. SAM 모델 구조

SAM은 다음 세 개의 주요 구성 요소로 이루어져 있다:

(1) Image Encoder (ViT-H backbone)

- 입력 이미지를 고정 해상도로 리사이즈하고, Vision Transformer (ViT-H/14)를 사용해 이미지의 **전역적 특징**을 추출한다.
- 해당 결과는 **한 번의 전처리로 캐시 가능**하여, 이후 마스크 생성 시 빠르게 활용된다.
- 아웃풋은 고해상도의 토큰 형태의 Feature Map.

(2) Prompt Encoder

- 사용자 입력(Prompt)을 인코딩하여 위치 정보 및 분할 의도를 벡터 형태로 생성한다.
- 프롬프트는 다음 세 가지 형태 중 하나:

- **Point:** 클릭한 좌표 및 포지티브/네거티브 플래그
- **Box:** 객체를 감싸는 바운딩 박스
- **Mask:** 이전 마스크를 입력하여 refinement 용도로 활용 가능
- 각 프롬프트는 위치 임베딩 + positional encoding을 통해 모델에 주입된다.

(3) Mask Decoder

- Image Encoder와 Prompt Encoder의 출력을 통합하여 최종 마스크를 예측하는 Transformer 기반 구조.
- 특징:
 - Prompt-guided attention을 수행
 - 각 인퍼런스마다 **3개의 마스크 후보**를 생성하고, confidence score를 함께 출력

 이렇게 함으로써 사용자가 후처리로 가장 적절한 마스크를 선택할 수 있다.

4. 학습 방식 및 데이터셋

SA-1B: Segment Anything 1-Billion Mask Dataset

- SAM을 훈련시키기 위해 Meta는 **1억 1천만 개의 이미지**에 대해 **10억 개의 고품질 마스크**를 생성한 **SA-1B 데이터셋**을 구축하였다.
- 이 데이터셋은 크게 두 단계로 생성됨:
 1. **인터랙티브한 수동 마스크 생성기(Human-in-the-loop) 사용**
 2. 자동화된 방법으로 대량의 마스크 확장 생성

 이 데이터셋은 모델의 제로샷 능력에 크게 기여함

5. 실험 및 성능

SAM은 다양한 벤치마크 데이터셋에 대해 제로샷 전이 성능을 평가하였다:

태스크	데이터셋	성능 (mIoU 등)	비고
인스턴스 분할	COCO	우수한 제로샷 성능	Fine-tuning 없이

시맨틱 분할	ADE20K	기존 모델에 근접	프롬프트 기반
객체 분할	LVIS, Pascal VOC 등	전반적으로 강력한 제로샷 성능	다양한 도메인에서 우수

또한 **Mask proposal (AMG)** 기능으로 프롬프트 없이 전체 이미지 객체를 분할하는 기능도 구현함.

6. 한계 및 논의

한계점	설명
입력 크기 고정	Image Encoder는 고정 해상도만 지원하여 고해상도 이미지 분할에는 제약 있음
작은 객체 탐지 한계	작은 객체에 대한 제로샷 성능은 상대적으로 떨어짐
연산량이 큼	특히 Image Encoder(ViT-H)는 무겁고 GPU 자원 소모가 큼
실제 응용엔 프롬프트 자동 생성 필요	사용자 클릭 없이는 상용화에 한계 → 다른 모델과 결합 필요

7. 결론 및 향후 연구 방향

SAM은 시각적 객체를 자유롭게 분할할 수 있는 범용 모델로, 세그멘테이션 분야의 패러다임을 바꿨다고 평가받는다.

특히 **프롬프트 기반 구조 + 대규모 학습 데이터**를 통해 강력한 제로샷 성능을 구현했다는 점이 혁신적이다.

향후 연구에서는 다음이 주요 이슈가 될 수 있다:

- 멀티모달 확장 (예: 텍스트 + 이미지)
- 고해상도, 실시간 응용 최적화
- 더 가벼운 구조로 경량화 및 모바일 적용