

SAM:Segment Anything

📅 작성일시	@2025년 4월 8일
🔍 강의 번호	BASE
📄 유형	논문리뷰
📎 자료	https://arxiv.org/pdf/2304.02643
☑ 복습	☐



1. Promptable Sementation이라는 새로운 접근

여러 유형의 프롬프트(점, 박스, 텍스트 등)로부터 즉시 유효한 분할 마스크를 추론하는 태스크를 제안하여, 다양한 다운스트림 작업을 프롬프트 엔지니어링으로 Zero-shot을 수행할 수 있게 했음

2. Segment Anything Model(SAM)의 경량 및 효율적 구조

무거운 이미지 인코더(사전 학습된 ViT) + 경량 마스크 디코더로 구성되어, 한 번 임베딩한 이미지를 대상으로 실시간에 가까운 속도로 여러 프롬프트에 대응 가능함

3. Ambiguity-Aware 마스크 예측

단일 프롬프트가 여러 객체를 지칭할 수 있는 모호성에 대비해, SAM은 최대 3개의 마스크를 동시에 제시해 유연성을 확보했음.

4. 대규모 데이터 엔진과 SA-1B 데이터셋

3단계 (수동 + 반자동 + 자동)방식으로 11M장 이미지와 10억 개 이상의 마스크를 자동 생성함으로써, 역대 최대 규모, 고품질 세그멘테이션 데이터셋을 구축했음.

5. Zero-shot 실험을 통한 범용성 증명

에지 검출, 객체 제안, 인스턴스 분할, 텍스트 기반 분할 등 다양한 과제에서 SAM이 학습 데이터 편향 없이도 종종 기존 완전 지도 모델과 견줄 만한 성능을 보여, 이미지 분할 파운데이션 모델의 가능성을 시사함.

ABSTRACT

1. 새로운 대규모 Segmentation 프로젝트

논문에서 “Segmenta Anything(SA)”프로젝트를 발표하며, 이는 새로운 태스크(promptable segmentaion), 모델(SAM, Segment Anything Model), 그리고 데이터셋(SA-1B)으로 구성되어 있음.

2. SA-1B 데이터셋 (대규모 마스크 데이터)

- 11M 이상의 이미지와 10억 개 이상의 고품질 마스크를 포함.
- 이미지는 라이선스를 준수하고, 얼굴 및 차량 번호판 등은 블러 처리하여 프라이버시를 보호함.

3. Promptable Segmentation

- 한 장의 이미지에 대해 다양한 “프롬프트”(포인트, 박스, 텍스트 등)를 제공하면, 해당하는 대상을 분할 마스크로 반환하는 새로운 태스크를 제안함
- 프롬프트가 애매할 경우에도, 합리적이라 판단되는 여러 개의 세분화 결과(마스크)를 동시에 낼 수 있도록 설계함.

4. Segment Anything Model(SAM)

- 강력한 이미지 인코더를 미리 한 번 실행해두고, 이후 빠르게 프롬프트를 반영해 마스크를 계산할 수 있도록 구성됐음.
- 다양한 스케일(대규모) 학습 데이터에 대해 학습했기 때문에, 새로운 이미지 분포나 새로운 태스크에 대해서도 zero-shot으로 활용가능함.

5. 주요 결과

- Zero-shot 전이 설정에서, 완전히 새로운 이미지나 과제에 대해 높은 정확도를 보임.
- 여러 가지 다운 스트림 작업(예: 객체 제안 생성, 에지 검출, 인스턴스 분할 등)에 대한 zero-shot 실험에서, 종종 기존에 완전히 지도 학습된 모델과 맞먹거나 능가하는 성능을 확인했음.
- 모델과 데이터셋은 공개되어, 비전 분야의 파운데이션 모델 연구에 기여할 것으로 기대됨.

Introduction

1. 파운데이션 모델의 부상

- NLP 분야에서는 웹 단위로 수집된 방대한 텍스트 데이터로 거대 언어 모델을 학습해 Prompting 방식으로 다양한 다운스트림 태스크에 적응시키는 흐름이 자리 잡았음.
- 비전 분야에서도 거대한 규모로 학습된 기반 모델이 활발히 연구되는 추세이며, 특히 텍스트-이미지 결합 (CLIP)에 한정되지 않고, 영상 자체에도 확장하려는 시도가 이루어지고 있음

2. Segmentation 분야의 파운데이션 모델 필요성

- 분할은 컴퓨터 비전에서 매우 중요한 문제이며, 사물이나 장면을 픽셀 단위로 구분해야 하는 까다로운 과제임
- 그러나 이미지 분할 마스크는 웹에서 풍부하게 존재하지 않고, 대규모 자동 수집이 어렵다는 한계를 가짐

3. Segment Anything 프로젝트의 목표

- “Promptable Segmentation”이라는 새로운 태스크를 정의해, 마스크 예측 모델이 다양한 형태의 프롬프트에 유연히 대응하도록 함.
- 이 모델이 zero-shot으로 적응할 수 있게 대규모 학습이 필요하므로, 자동화된 어노테이션 루프를 구성하여 11M장, 10억 개 이상의 마스크를 얻음
- SAM은 이런 데이터로 학습되어, 실시간 가까운 속도로 promptable segmentation을 수행하고, 다른 태스크에도 확장 가능함.

4. Promptable Segmentation

- 기존의 Interactive Segmentation과 유사하지만, 다양한 유형(점, 박스, 텍스트 등)의 프롬프트를 폭넓게 허용한다.
- 모델이 애매모호한 프롬프트에 대해서도 최선의 마스크를 반환하도록 학습한다(또는 여러 개를 동시에 출력).
- “Prompt Engineering”을 통해 **다운스트림 분할 작업**(예: 인스턴스 분할, 전경/배경 분할, 특정 클래스 분할 등)을 Zero-shot으로 해결할 수 있다.

5. Data Engine 및 SA-1B

- 실제로 **“Model-in-the-loop”** 방식의 데이터 구축을 통해 **SA-1B**라 불리는 **대규모·다양한** 세그멘테이션 마스크를 확보했다(1단계: 수작업 보조, 2단계: 반자동, 3단계: 완전 자동).
- 최종적으로는 10억 개 이상의 마스크가 자동으로 생성되었으며, 사람을 통해 품질을 검사한 결과, 대부분의 마스크가 90% 이상의 IoU를 기록할 정도로 **높은 정확도**를 보였다.

6. 실험 결과 요약

- 20여 개의 서로 다른 분할/에지 검출/객체 제안/인스턴스 분할 데이터셋을 대상으로 Zero-shot 성능을 평가했을 때, 종종 기존의 완전 지도학습 결과와 견줄 만한 성능을 달성한다.
- 특히 점(포인트) 하나만 주어도, 매우 높은 품질의 마스크를 생성해낼 수 있음을 사람 평가(Human Study)를 통해 확인했다.
- Promptable segmentation 접근으로 인해, 사전에 정의한 세그멘테이션 태스크뿐 아니라, 새로운 시나리오에도 즉각적으로 활용 가능성을 보여준다.

7. 결론

- Segment Anything은 **Segmentation** 문제에서 “파운데이션 모델”을 구축하기 위한 첫 시도로, 대규모 데이터(SA-1B)와 프롬프트 기반 모델(SAM)을 제안한다.
- SAM이 제안하는 마스크 출력이 종종 완전한 지도학습 모델에 맞먹는 성능을 보여주며, **학계에서 향후 해당 접근이 널리 활용**될 가능성을 시사한다.

- 코드·모델·데이터셋을 공개함으로써, 연구자들의 재현·응용·확장을 촉진하고자 한다.

Segment Anything Task

1. Promptable Segmentation 정의

- 기존의 분할(semantic, instance, panoptic)과 달리, 이미지를 입력받아 다양한 프롬프트(점, 박스, 텍스트 등)에 대응하여 **유효한 마스크**를 산출하는 문제를 정의한다.
- 예컨대, 한 점이 주어졌을 때("이 위치의 객체를 찾아라")나, 텍스트("a cat with black ears")를 주었을 때, 해당하는 분할 마스크를 반환해야 한다.
- 모호성이 존재할 경우(점 하나만 주어 여러 대상 가능 시), **복수의 마스크**를 출력하여 어느 한 객체에만 한정되지 않도록 설계했다.

2. Pre-training

- 모델이 어떤 프롬프트가 들어와도 합리적 마스크를 내놓도록, 프롬프트 기반 학습을 대규모로 진행한다.
- 구체적으로, '점'이나 '박스' 등의 기하학적 프롬프트를 시뮬레이션하여 모델이 다양한 경우를 학습하게 한다.
- 모호성을 처리하도록 여러 가지 마스크를 동시에 예측하게 하되, 지도 신호는 (실제 정답 마스크 대비) 가장 정확한 예측에 대해서만 역전파한다.

3. Zero-shot Transfer

- Promptable Segmentation으로 사전 학습된 모델은, 추후 **다운스트림 세그멘테이션**에 그대로 활용될 수 있다.
- 예: 물체 검출기로부터 받은 박스("cat box")를 프롬프트로 주어 **인스턴스 분할**을 하거나, 사용자의 클릭만으로 대상을 분할(interactive segmentation)하는 등 다양한 응용이 가능하다.
- 이처럼 프롬프트라는 일반적 인터페이스를 통해 **다양한 태스크**에 대응하도록 하는 것이 목표다.

Segment Anything Model (SAM)

1. 모델 구성

- **이미지 인코더**: 대규모 자가(supervised + MAE 사전 학습) 학습된 ViT 계열 네트워크로, 이미지 전체를 한 번만 처리해 **이미지 임베딩**을 생성한다.
- **프롬프트 인코더**: 프롬프트 종류(점, 박스, 마스크, 텍스트 등)에 따라 해당 정보를 256차원 벡터로 변환한다.
- **마스크 디코더**: 이미지 임베딩과 프롬프트 임베딩을 결합해, 최종적으로 **마스크**를 빠르게 복원(추론)한다.
 - 여러 프롬프트 입력(점 여러 개 등)을 고려해 **50ms** 내에 예측 가능하도록 경량화된 구조(Transformer 기반)를 채택했다.

2. Ambiguity-aware 디자인

- 하나의 점(프롬프트)이 여러 대상에 해당될 때(웃 위의 점인지 사람 전체인지 등), 평균적으로 합쳐진(어중간한) 마스크가 나오는 걸 방지하기 위해 **최대 3개의 후보 마스크**를 동시에 예측한다.
- 이 중 가장 신뢰도가 높은 마스크가 모델 기본 출력이 되지만, 필요 시 다른 후보를 확인할 수 있도록 설계했다.

3. 학습 방식

- **인터랙티브 세그멘테이션** 설정에서 영감을 받아, 마스크를 예측하고 그 오차 위치에 추가 점(프롬프트)을 찍는 식으로 총 11번(최대) 반복하여 학습 샘플을 생성한다.
- 모델이 모호한 상황에서도 항상 타당한 마스크를 예측하게끔 훈련 목표를 설정하고, Focal Loss와 Dice Loss를 조합해 학습한다.

4. 효율성

- 이미지 인코더는 무겁지만 한 번만 수행하고, 프롬프트 인코더·마스크 디코더는 빠르게 동작한다.
- 따라서 한 이미지 위에서 다양한 프롬프트를 시도할 때, 실시간(약 50ms)으로 세그멘테이션 결과를 얻을 수 있다.

5. 활용성

- 정교한 후처리 없이 **에지 검출, 객체 제안(프로포절), 인스턴스 분할** 등 여러 과제에 Zero-shot으로 적용이 가능하며, 성능 또한 기존 완전 지도학습 모델과 견줄 만한 결과를 보였다.
- 텍스트 프롬프트에 대한 시범적 실험에서도, CLIP 임베딩을 활용해 원하는 객체를 마스크로 추출할 수 있음을 시사했다.

Segment Anything Data Engine

(1) 데이터 규모 문제

- **Segmentation**에 필요한 마스크는 인터넷에 풍부하게 존재하지 않아, 기존 대규모 데이터 구축 방식(CLIP 등의 웹 스크래핑)으로는 어려움이 크다.
- 따라서 고성능 분할 모델을 “루프”에 참여시켜 **마스크를 반자동·자동으로 대규모로 생성**하는 전략을 선택했다.

(2) 3단계(Stages)로 구성된 데이터 엔진

1. Assisted-manual (단계 1)

- 초기에 마련된 DeepLab 계열 등 일부 사전 학습된 분할 모델을 활용해, **인터랙티브 세그멘테이션** 방식으로 사람(전문 어노테이터)이 객체를 마스크로 그린다. 모델 예측을 보조로 활용하되, 사람이 직접 클릭·브러시 수정함.
- 이 과정에서 얻은 마스크를 바탕으로 모델(SAM)을 재학습 → 모델 정확도 증가 → 이후 사람이 더 빠르게 어노테이션 가능.

2. Semi-automatic (단계 2)

- 미리 **모델이 자동 생성**한 마스크 중 확실해 보이는(=신뢰도 높은) 것들은 바로 채택, **부족한 부분만** 사람이 보완하여 추가 마스크를 생성.
- 이로써 어노테이션의 속도와 다양성을 동시에 높인다.
- 다시 SAM을 학습시켜 모델 성능을 지속적으로 개선.

3. Fully automatic (단계 3)

- 최종적으로 충분히 강력해진 모델(SAM)을 이용해, **완전 자동**으로 마스크를 만들 수 있게 된다.
- 이미지마다 **고정된 그리드**로 여러 점을 찍어 요청(prompt)하고, SAM이 다중 마스크를 자동 생성한 뒤, 품질이 낮은 마스크는 안정성·신뢰도 지표(IoU 추정치, 마스크 안정성 등)로 걸러낸다.
- 이미지를 부분적으로 크롭해 더 미세한 객체를 잡아내는 과정도 수행하여, 최종적으로 한 장당 평균 100개 정도 마스크를 얻는다.

(3) 루프의 결과: 대규모 자동 마스크 생성

- 위 과정을 반복함으로써, **수작업 없이도** 전 세계의 다양한 이미지에 대해 방대한 마스크를 생성할 수 있었다.
- 최종적으로 11M(천만)장 이미지를 전수 처리해 **10억 개 이상의 마스크**를 확보했다.

Segment Anything Dataset (SA-1B)

(1) 구성 및 특징

- **SA-1B**는 약 11M장의 고품질 이미지와 **1.1B(10억+)의 마스크**로 구성된 데이터셋이다.
- 이미지들은 **라이선스/프라이버시**를 고려(예: 얼굴, 차량 번호판 블러 처리)하여 확보했으며, 해상도는 짧은 변이 1500픽셀 수준으로 다운샘플링되어 제공된다.

(2) 마스크 품질

- 대부분(99% 이상)은 **Fully Automatic** 방식으로 생성된 마스크이지만, 일부 표본(수천 장)을 전문가가 다시 검수·수정했을 때에도, 94% 이상이 90% IoU를 넘을 정도로 품질이 높게 확인되었다.
- 자동 생성임에도, 마스크 모양 다양성(크기·위치·복잡도)이 매우 뛰어나다.

(3) 기존 세그멘테이션 데이터셋과 비교

- LVIS·COCO·Open Images 등 그동안 대규모라 불리던 데이터셋 대비, 이미지 수(11M)나 마스크 수(10억)에서 압도적이다 (수백 배 규모).
- 마스크당 객체 범위(크기·중심 위치 등)도 더 넓고 다양해, 중심부 편향(center bias)이 상대적으로 적다.

(4) 지리·경제권 다양성

- 이미지들의 메타정보를 분석하면, 기존 데이터셋(예: COCO, Open Images)보다 **아시아·유럽·중간 소득 국가** 등에서의 사진 비중이 더 높아졌다.
- 여전히 지역별 분포 불균형이 있으나, 전체적으로는 이전 대비 **더 다양한 국가**에서 촬영된 사진이 포함된 편이다.

(5) 활용 및 공개

- SA-1B는 SAM 모델을 학습하기 위해 제작되었으며, **대규모 세그멘테이션 파운데이션 모델** 연구에 유용한 자료가 될 수 있다.
- **연구 목적으로** 공개되며, 다운로드 시 라이선스를 준수해야 하며 **사람 식별 시도** 등은 금지된다.

Segment Anything RAI Analysis (Responsible AI 분석)

1. 데이터셋(SA-1B)의 지리 및 소득 수준 다양성

- 사진의 촬영 위치(추정)를 통해 분석해본 결과, 아시아·유럽·중간 소득 국가의 비중이 기존 COCO·Open Images 대비 크게 늘었다.
- 아프리카, 저소득 국가 등 여전히 상대적으로 적게 포함된 지역이 있지만, 그럼에도 이전 데이터셋들에 비해 **지리적 다양성**이 개선되었다.

2. 인물(피사체)에 대한 공정성(Fairness) 분석

- Segment Anything Model(SAM)이 성별 표현, 나이, 피부 톤 등에 따라 예측 성능이 달라지는지 확인.
- MIAP(More Inclusive Annotations for People) 등 특정 테스트셋에서 사람(혹은 의류)에 대한 분할 결과를 비교·평가한 결과, 대체로 큰 차이는 없었으나(통계적 오차 범위 내), 일부 속성(예: 특정 연령대, 특정 성별)에서 약간의 편차가 관찰되었다.
- **결론적으로**, 사람을 분할할 때 전혀 편향이 없는 것은 아니므로, **특정 다운스트림 태스크**에 사용할 경우, 공정성 이슈가 없는지 추가 점검이 필요하다.

3. Bias 및 윤리적 고려

- 데이터셋 자체에 존재할 수 있는 잠재적 편향이나 지역별·소득 수준별 차이 등 다양한 요인을 논의하며, **실제 서비스나 연구**에 적용할 때는 이런 점을 고려해야 함을 강조한다.

Zero-Shot Transfer Experiments

논문에서 제안된 SAM이 다양한 다운스트림 태스크에 **Zero-shot**으로 적용될 수 있음을 증명하기 위해 진행한 실험들이다.

1. 단일 포인트 프롬프트

- 하나의 점(클릭)만 주어도, 해당 위치의 객체를 잘 분할하는지 평가.
- 총 23개나 되는 다양한 분할 벤치마크에서 실험했으며, 기존 인터랙티브 세그멘테이션 모델(RITM 등)과 비교 시, SAM이 더 높은 **주관적 품질 평점**을 받고, IoU 역시 많은 데이터셋에서 우세하거나 비슷했다.
- 모호한 경우를 위해 다중 마스크를 출력하는 **"Ambiguity-aware"** 특성이 큰 장점으로 작용.

2. Edge Detection(에지 검출)

- BSDS500 데이터셋에서 SAM이 자동 생성한 마스크를 에지 맵으로 변환해 평가.
- 전통적인 에지 검출(Canny 등)보다 **우수한** 성능을 보이며, 일부 학습된 최신 모델과도 견줄 정도임을 확인.

3. Object Proposal(객체 제안)

- LVIS 등에서 **객체 제안**으로 사용 시, 중간·큰 물체나 희귀 카테고리 대해서는 전통적인 강력 모델(ViTDet-H)과 맞먹거나 능가하는 좋은 Recall을 보였다.

4. Instance Segmentation(인스턴스 분할)

- COCO, LVIS에서 객체 검출 결과(박스)를 SAM에 prompt로 제공 → 인스턴스 마스크를 Zero-shot으로 생성.
- AP 측면에서는 전적으로 학습된 모델보다 다소 떨어지나, **경계 품질**이나 사람 평가면에서 더 낫다는 결과도 관찰됨(데이터셋의 편향·마스크 품질 이슈).

5. Text-to-Mask

- 초기 연구로, CLIP의 텍스트 임베딩을 SAM의 프롬프트로 제공해, “a wheel”, “a wiper” 등 텍스트 질의로 분할 가능성을 보였다.
- 정확도는 아직 제한적이지만, 프롬프트에 점(클릭)까지 함께 주면 성능이 향상되는 등, 텍스트 기반 세그멘테이션의 잠재력을 시사.

Discussion

1. 파운데이션 모델 관점

- SAM은 대규모 데이터 및 네트워크를 통해 여러 태스크에 Zero-shot으로 적용된다는 측면에서 **비전 분야의 파운데이션 모델** 역할을 지향한다.
- 다만, **이미지 분할**에 특화된 파운데이션 모델이라는 점에서 더 폭넓은 비전 문제 전반에는 제한이 있을 수 있다.

2. 조합성(Compositionality)와 확장

- SAM이 다른 모듈(ex: 객체 검출기, 텍스트 인코더 등)과 **조합**돼 다양한 작업(3D 복원, Wearable 컴퓨팅, AR 등)에 활용될 수 있음을 기대한다.

3. 한계

- 작은 디테일(가느다란 구조물 등)을 놓치거나, 분리된 작은 요소를 잘못 포함할 수 있음.
- 많은 점(20점 이상)을 요구하는 고정밀 인터랙티브 환경에서는 기존 전용 모델이 더 나은 성능을 낼 수 있다.
- 텍스트 입력만으로는 아직 완벽하지 않으며, 학습 데이터의 중첩된 편향을 완전히 배제하기 어렵다.

4. 결론

- **Segment Anything** 프로젝트는 “Promptable Segmentation”이라는 일반화된 접근법, SAM 모델, 그리고 SA-1B라는 대규모 데이터셋을 통해, **대규모 분할 파운데이션 모델**의 가능성을 보여줬다.
- 모델, 데이터셋, 코드 공개로 연구자들이 폭넓게 활용·확장하기를 기대하며, 후속 연구에서 SAM을 어떤 식으로 조합·응용할지에 대한 방향성을 제시한다.