

Sequence to Sequence Learning with Neural Networks

0. Abstract

- 서로 길이가 다른 입력과 출력을 처리하는 모델 제안.
- 두 개의 **RNN**을 사용: 하나는 **입력 시퀀스를 인코딩**, 다른 하나는 **출력 시퀀스를 디코딩**.
- 성능 평가: 기계 번역 데이터셋에서 강력한 성능을 보임.
- 긴 문장도 효과적으로 번역 가능.

1. Introduction

- 기존 NMT 기법은 문장 길이가 다를 때 대응이 어려움.
- 제안 방법: **Encoder-Decoder** 구조로 시퀀스를 시퀀스로 변환.
- *입력 문장을 고정 길이 벡터로 변환(Encoding)**하고, 이를 기반으로 **출력 문장 생성 (Decoding)**.
- 장점: 문장 길이 불일치 문제 해결 가능.
- Google의 **WMT'14 영어-프랑스어 기계번역 데이터**에서 좋은 성과를 보임.

2. The model

- 구조: **2개의 RNN 구성** (Encoder RNN, Decoder RNN).
- **Encoder**: 입력 시퀀스를 받아 **고정 길이 컨텍스트 벡터**로 변환.
- **Decoder**: 컨텍스트 벡터를 기반으로 출력 시퀀스를 생성.
- 인코더와 디코더 모두 **LSTM** 사용.
- 디코더는 이전 단어를 조건으로 다음 단어를 생성 (Conditional Language Model 형태).

3. Experiments

3.1 Dataset details

- 사용 데이터: **WMT'14 영어-프랑스어 번역 데이터셋**.
- 약 1200만 문장 쌍으로 구성.
- 학습셋: 약 348M 영어 단어, 381M 프랑스어 단어.

3.2 Decoding and Rescoring

- 디코더는 **Beam Search** 사용.
- Beam size는 1, 2, 5, 10으로 실험.
- Beam Search 결과보다 성능을 더 높이기 위해 **n-best list rescoring 기법** 활용.
 - 입력 문장을 뒤집어(Reverse) 학습한 별도 모델을 사용해 **재평가 (Rescoring)** 수행.
 - 두 모델 점수의 평균으로 최종 점수 결정.

3.3 Reversing the Source Sentences

- 학습 시 **입력 문장을 뒤집는(reverse)** 기법 적용.
- 이유: 역순 정렬 시, 디코더 초기 단계에서 중요한 정보(문장 끝 정보)를 더 빨리 접할 수 있음.
- 성능 향상 효과 확인.

3.4 Training details

- Optimizer: Stochastic Gradient Descent (SGD).
- 학습률: 0.7, decay 적용.
- Gradient Clipping 적용 (Norm 5로 클리핑).
- 학습 시간: 약 10일 (8 GPUs 사용).
- Mini-batch size: 128.
- Vocabulary: 영어 160,000 단어, 프랑스어 80,000 단어.

3.5 Parallelization

- 8 GPUs 병렬 학습.
- 각 GPU는 독립적으로 Batch 처리, **Parameter Server** 방식으로 매 Step마다 파라미터 업데이트.

- GPU 간 동기화는 최소화해 성능 최적화.

3.6 Experimental Results

BLEU Score (WMT'14 영어-프랑스어):

- 기존 SOTA (MT 시스템): 33.3
- Seq2Seq (제안 모델): 34.8 (Beam Search 사용 시)
- Reverse & Rescoring 적용 시: 36.5 (최종 최고 성능)

3.7 Performance on long sentences

- 긴 문장 성능 분석.
- 문장이 길어질수록 성능 저하가 발생하지만, 제안 모델은 상대적으로 성능 유지력이 좋음.
- 특히 입력을 뒤집고 Rescoring 기법을 적용하면 긴 문장에서도 성능 향상 확인.

3.8 Model Analysis

- **컨텍스트 벡터의 한계:** 문장 전체 정보를 하나의 벡터로 담아야 해서 긴 문장 처리 한계 존재.
- 해결 방안: Attention Mechanism 필요성 시사 (하지만 본 논문에서는 구현하지 않음, 이후 연구로 연결됨).
- 시각화 결과: 같은 문장도 문장 길이에 따라 번역 품질 차이가 발생함.

4. Related work

- 기존 문장 변환 모델은 정해진 길이의 입력과 출력을 전제로 설계됨.
- RNN 기반 번역 시도는 있었지만, 시퀀스 길이가 다를 경우 처리가 어려웠음.
- 본 논문은 **Variable-length Sequence to Sequence 학습 가능성**을 최초로 보인 연구.
- 이후 Attention, Transformer 등의 기반이 됨.

5. Conclusion

- **RNN Encoder-Decoder 구조 제안.**
- 다양한 길이의 입력과 출력 처리 가능.
- 기계번역에서 SOTA 달성.

- **Reverse 입력과 Rescoring 기법**이 성능 향상에 효과적임.
- 긴 문장에서도 성능 유지가 가능한 **Seq2Seq 모델** 제시.
- 컨텍스트 벡터만 사용하는 방식의 한계도 지적하며, 이후 연구 방향 제시 (Attention 도입 시사).