

Seq2Seq 논문리뷰_윤혜주

Sequence to Sequence Learning with Neural Networks (Sutskever et al., 2014) 리뷰

1. Introduction (서론)

- 인간의 언어는 길이가 고정되지 않으므로, 기존 신경망은 입력과 출력의 길이가 다른 문제를 다루기 어려움. (기존의 DNN은 병렬처리로 음성인식, visual object recognition 등과 같은 태스크에서 우수한 성능을 보임. 하지만 DNN은 고정된 입력과 고정된 차원의 크기를 가지는 경우에만 적용이 가능하다는 문제가 있음. 고정된 벡터의 크기를 가지지 않는 음성인식, 기계 번역에서는 이게 중요한 문제점이 됨.)
- 이를 해결하기 위해 **Sequence to Sequence (Seq2Seq) 모델**을 제안함.
- 이 모델은 **두 개의 RNN (Recurrent Neural Network)** 을 사용하여 문장을 인코딩(encoding)하고 디코딩(decoding)하는 구조.
- 이때 장기적 시간 의존 데이터에 대해 성능이 좋은 LSTM을 사용하여 input sequence를 읽어서 고정된 큰 차원의 벡터 표현을 얻고, 또 다른 LSTM을 사용하여 output sequence를 추출함
- 기계 번역과 같은 자연어 처리(NLP) 작업에서 뛰어난 성능을 보임.

2. Model Architecture (모델 구조)




Figure 1: Our model reads an input sentence “ABC” and produces “WXYZ” as the output sentence. The model stops making predictions after outputting the end-of-sentence token. Note that the LSTM reads the input sentence in reverse, because doing so introduces many short term dependencies in the data that make the optimization problem much easier.

- Seq2Seq 모델은 **Encoder-Decoder 구조**를 가짐.

- **Encoder:** 입력 시퀀스를 **고정된 길이의 벡터(컨텍스트 벡터)** 로 변환. (Encoder 부분에서 Input Sentence를 누적된 Cell State로 계산하는데, 이때 Sequence의 길이에 관계없이 EOS토큰이 나올때까지 Input을 계속 모델에 입력)
- **Decoder:** 이 벡터를 기반으로 출력을 생성.
- RNN 기반 모델이지만, 특히 **LSTM (Long Short-Term Memory) 네트워크**를 사용하여 장기 의존성(long-term dependencies)을 효과적으로 처리. (LSTM은 우리의 입력과 잠재벡터 H를 고려해 Vecotr H를 만들고 이를 통해 output을 내놓는 형태)

$$h_t = \text{sigm}(W^{hx}x_t + W^{hh}h_{t-1})$$

$$y_t = W^{yh}h_t$$

LSTM 모델이 하고자 하는 것 → 우리가 출력한 (y_1, y_2, y_3)가 input $X=(x_1, x_2, \dots, x_t)$ 에 대해 조건부 확률에서 최대화하고 그렇게 만들어낸 예측 문장 T' 가 Target sentence T 와 최대한 유사하게 하는 것

- 이때 4층의 Deep한 LSTM 모델을 사용하였고, 문장을 역순으로 읽도록 만들었음(이렇게 진행하면 출력 문장의 초반 단어와 입력 문장의 초반 단어가 더 가까워지므로 성능이 좋기 때문)

4. Experiments (실험 결과)

논문에서는 **WMT'14 영어-프랑스어 기계 번역(MT) 태스크**에 Seq2Seq 모델을 적용하여 실험을 진행함.

이 실험에서는 두 가지 방법을 사용했음:

1. 기존의 통계적 기계 번역(SMT) 시스템 없이 직접 번역 수행
2. SMT 시스템에서 생성한 n-best 리스트를 다시 점수 매기기(Rescoring)

3.1 데이터셋 세부 정보

- WMT'14 영어-프랑스어 데이터셋 사용
- 총 1,200만 개 문장 학습 (영어 3.04억 단어, 프랑스어 3.48억 단어)
- 학습 데이터는 공개적으로 제공되는 정제된(clean) 서브셋에서 추출
- 단어를 벡터 표현으로 변환해야 하므로, 고정된 단어 사전(vocabulary) 사용
 - 원문(영어): 상위 16만 개 단어 사용
 - 번역문(프랑스어): 상위 8만 개 단어 사용
 - 사전에 없는 단어는 특별한 "UNK" 토큰으로 대체

3.2 디코딩(Decoding) 및 Rescoring

- LSTM 모델 학습 목표:
 - 번역문 T 가 주어졌을 때 입력 문장 S 의 로그 확률을 최대화하는 방식으로 학습
- 디코딩 방식 (Beam Search)
 - Beam Search를 사용하여 번역문 생성
 - 빔 크기 B 만큼 상위 후보 문장(Partial Hypothesis)을 유지하면서 확장 BB
 - 각 후보 문장을 가능한 모든 단어로 확장한 후, 확률이 높은 BBB개만 유지
 - "<EOS>"(문장 종료) 토큰이 등장하면 최종 번역 결과로 선택
 - 빔 크기 1~2 정도만 사용해도 성능이 충분히 확보됨
- Rescoring (점수 재계산) 방법
 - 기존 SMT 시스템이 생성한 1000개의 후보 번역 리스트(n-best lists) 를 LSTM 모델을 이용해 다시 점수 매김
 - LSTM 모델이 계산한 로그 확률과 기존 점수를 평균 하여 최종 번역문 선택

3.3 입력 문장 순서 뒤집기 (Reversing the Source Sentences)

- LSTM 모델이 긴 문장에서의 의존 관계(Long-term dependency)를 학습하기 어려운 문제가 있음.
- 이를 해결하기 위해 입력 문장의 단어 순서를 반대로 뒤집음 (출력 문장은 그대로 유지).
- 효과:

- 테스트 Perplexity(혼란도): 5.8 → 4.7 감소 (더 나은 확률 예측)
 - BLEU 점수(번역 품질 평가 지표): 25.9 → 30.6 증가
 - 이유:
 - 보통 원래 문장 순서에서는 입력 단어와 번역 단어 사이의 거리가 멀어지므로, 모델이 이를 학습하기 어려움.
 - 입력 문장을 뒤집으면 번역문과의 "초기 단어 매칭"이 쉬워지고, **최소 시간 지연 (minimal time lag)** 이 줄어듦.
 - 결과적으로 역전된 입력 문장이 LSTM의 메모리 활용도를 높이고, 긴 문장 번역 성능을 개선함.
-

3.4 학습 세부 정보 (Training Details)

- LSTM 모델 구조:
 - 깊은 LSTM (Deep LSTM) 사용 (4개 층, 각 층마다 1000개 셀)
 - 각 단어는 1000차원 벡터로 임베딩
 - 전체 모델의 파라미터 수: 3.84억 개
 - 이 중 순환 연결(Recurrent Connections)은 6400만 개 (인코더 3200만 개 + 디코더 3200만 개)
 - 학습 설정:
 - 모든 가중치는 -0.08 ~ 0.08 사이에서 균등 분포로 초기화
 - 확률적 경사 하강법(SGD) 사용 (Momentum 없이, 초기 학습률 0.7)
 - 5 Epoch 이후 학습률을 절반씩 감소, 총 7.5 Epoch 동안 학습 진행
 - 128개 문장 단위(Mini-batch)로 학습 진행
 - Exploding Gradient 문제 해결:
 - 그래디언트가 L2 norm 5를 초과하면 크기를 5로 조정 (Gradient Clipping 적용)
 - Batch 내부 문장 길이 정렬
 - 랜덤하게 배치된 128개 문장 길이가 다르면, 짧은 문장이 많아 계산이 낭비됨
 - 같은 길이의 문장을 묶어 배치하여 2배 속도 향상
-

3.5 병렬 처리 (Parallelization)

- **C++ 기반 단일 GPU LSTM 모델의 처리 속도:**
 - 초당 1700 단어 처리 → 속도가 너무 느림
- **8-GPU 병렬화 적용:**
 - 4개 GPU → LSTM 각 층에 분배
 - 4개 GPU → Softmax 연산 분배 (1000 × 20000 행렬 연산 처리)
 - 최종 속도: 초당 6300 단어 처리 (영어+프랑스어)
 - 미니배치 크기 128 기준, 학습 소요 시간: 약 10일

5. Related Work (관련 연구)

- 기존 RNN을 활용한 언어 모델, 기계 번역 모델, 오토인코더(autoencoder) 연구를 참고.
- Attention Mechanism이 없는 초기 Seq2Seq 모델의 한계를 설명.

6. Conclusion (결론)

- RNN 기반 **Encoder-Decoder** 모델이 기계 번역을 포함한 NLP 문제에 효과적임을 증명.
- 다만, 고정된 길이의 컨텍스트 벡터로 인해 긴 문장 번역 시 성능이 저하됨.
- 이후 연구(Attention Mechanism)로 이 문제를 해결할 필요가 있음.