

Abstract

DNNs는 difficult learning tasks에서 훌륭한 performance를 낸다.

Although DNNs work well whenever large labeled training sets are available, they cannot be used to map sequences to sequences.

문제 상황 : 입력 -> 출력 모두 sequence인 경우(연속된 데이터) 최적화 x

해결 방식 : multilayered LSTM 사용 0 < input sequence를 fixed dimensionality로 vector mapping 또한 Another deep LSTM으로 vector 를 target sequence로 decode

실험 목적 : English -> French 언어로 translation

데이터 : WMT'14 dataset

1. Introduction

Abstract에서 초기 언급한대로 DNNs가 강력하긴 하다

But sensibly encoded with vectors of fixed dimensionality한 상황에서 잘 작동, 입력과 출력을 고정된 차원의 벡터로 인코딩 할 수 있는 문제에만 적용 가능

이러한 방식으로 해결하겠다.

1. 첫 번째 LSTM이 입력 sequence를 한번에 한 타임 스텝씩 읽어 들여, 고정된 크기의 벡터 표현을 생성
2. 두 번째 LSTM이 벡터 표현에서 출력 sequence를 추출

Sequence to sequence 학습문제를 해결하려 했던 기존 연구들도 언급하나 문제가 있음.

사전 지식

1. BLUE score : 기계 및 번역 자연어 생성 모델의 성능을 평가하는 지표
2. SMT : 통계 기반 번역 시스템

핵심 : input sentence를 reverse하게 넣어줌 -> 단기 의존성을 유도하여 최적화 문제를 훨씬 쉽게 만듦

훈련 및 데이터셋에서 소스 문장의 단어 순서를 뒤집음(but target 문장 순서는 변경 x)

➔ 단기 의존성이 생성되어 최적화 문제가 단순

A useful property of the LSTM is that it learns to map an input sentence of variable length into a fixed-dimensional vector representation.

2. The model

RNN은 입력과 출력간의 정렬이 사전에 알려져 있을 경우 쉽게 시퀀스를 시퀀스로 변환 가능 BUT 입력 시퀀스와 출력 시퀀스의 길이가 다르며, 이들 사이의 관계나 복잡하고 비단조적인 경우 하나의 RNN을 사용하여 입력 시퀀스를 고정 크기 벡터 변환을 하는 방식도 있지만 장기 의존성 문제 발생

LSTM으로 해결 LSTM은 장기적인 시간적 의존성을 갖는 문제를 학습 할 수 있는 것으로 알려짐 LSTM 목표 조건부 확률 $p(y_1, y_2, \dots, y_t | x_1, x_2, \dots, x_t)$ 를 추정 - softmax를 통해 확률 계산

본 연구모델이 위 접근 방식과 차이

1. 입력 시퀀스용 LSTM과 출력 시퀀스 LSTM을 따로 사용
2. 깊은 LSTM 사용
3. 입력 문장의 순서를 뒤집음

3. Experiments

실험 방법

1. 기존 SMT 시스템을 참조하지 않고 입력 문장을 직접 번역하는 방식
2. SMT 기반 시스템의 n-best 리스트를 다시 점수화 하는 방식

3.1. Dataset details

WMT'14 English to French dataset 사용

3.2. Decoding and Rescoring

소스 문장 S 가 주어졌을 때 정확한 번역 T 의 로그 확률을 최대화

$$\frac{1}{|S|} \sum_{(T,S) \in \mathcal{S}} \log p(T|S)$$

학습 목적 함수

번역 생성은 빔 search decoder 사용. 매 타임스텝에서 어휘집의 모든 단어로 확장한 후, 가장 가능성 높은 B 개만 남기는 방식으로 작동 "<EOS>"가 추가된 가설의 완전한 번역 후보를 저장하여 빔 크기 2만으로도 대부분의 빔 search 효과를 얻음. 기존 SMT 시스템의 1000-BEST 리스트를 LSTM으로 다시 점수화 하여 번역 성능을 향상 시키고 이를 위해 LSTM이 예측한 로그 확률과 기존 시스템의 점수를 평균하여 최종 점수를 계산

3.3. Reversing the source Sentences

LSTM은 장기 의존성이 있는 문제를 해결 할 수 있지만

놀라운 발견 : 소스 문장을 뒤집을수록 LSTM이 훨씬 더 잘 학습 데이터에 많은 단기의 의존성이 추가 되었기 때문이라고 추측

3.4. Training details

초기화를 어떻게 하고 최적화 방법과 미니배치 설정 그래디언트 폭발 방지 문장 길이에 따른 최적화 기법을 간략하게 언급

3.5. Parallelization

C++ 기반 single GPU를 돌리는데 초당 1,700 단어 학습 가능 but 너무 느림. 8-GPU로 parallelized out model 하였다고함.

그래서 각각의 GPU로 1개의 layer를 학습해서 8-gpu

아마 deep LSTM의 layer는 4개인데 input LSTM 부분과 output LSTM 서로 다른 LSTM을 사용하여 4+4=8을 의미해서 8 GPU이지 않나 본인 생각

3.6. Experimental Results

비록 실험에서 나온 모델의 BLUE score가 여태 나온 번역 모델 중 가장 높은 blue score를 기록 한 것은 아니지만 SMT 기반 모델보다 blue score를 뛰어넘는 최초의 사례

3.7. Performance on long sentences

We were surprised to discover that the LSTM did well on long sentences, which is shown quantitatively in figure 3. Table 3 presents several examples of long sentences and their translations.

3.8. Model Analysis

같은 input data에 대해 해당 연구에서 나온 모델이 번역 한 것과 구글 translation의 번역 결과를 보여줌

4. Related work

Sequence to sequence 학습문제를 해결하려 했던 기존 연구들도 언급하나 문제가 있음.

5. Conclusion

1. 소스 문장을 역순으로 학습했을 때 성능이 크게 향상
2. LSTM이 매우 긴 문장도 올바르게 번역 가능

의의 : 단순하고 직관적인 방식(LSTM 모델 기반의 접근법)이 기존 SMT 시스템보다 더 우수한 성능을 낼 수 있음을 입증

6. Acknowledgments

관련 논문

