

Sequence to Sequence Learning with Neural Networks

작성 일시	@2025년 3월 6일
강의 번호	BASE
유형	논문리뷰
자료	https://proceedings.neurips.cc/paper_files/paper/2014/file/a14ac55a4f27472c5d894ec1c3c743d2-Paper.pdf
복습	☐

Abstract

시퀀스 입력을 받아 시퀀스 출력을 생성하는 과제를 완전히 뉴럴 네트워크로 해결하는 새로운 접근 방식을 소개한다는 핵심 내용을 담고 있다. 주요 요점은 다음과 같다:

1. 통합된 엔드-투-엔드 학습
 - 입력 시퀀스를 인코딩(encoding)하는 RNN(또는 LSTM)과, 이를 기반으로 새로운 시퀀스를 디코딩(decoding)하는 RNN(또는 LSTM)을 연결해, 통합된 뉴럴 네트워크로 시퀀스 변환 문제를 해결한다.
2. 기계 번역 적용
 - 영어→프랑스어 번역 과제에서 이 접근법을 적용해, 전통적인 통계적 번역 방식보다 더 나은 번역 품질을 달성한다.
3. 대규모 신경망 활용
 - 대규모 데이터와 큰 네트워크(빅 LSTM)를 학습해 성능을 높였으며, 이를 통해 확장 가능성을 입증했다.
4. 입력 토큰 순서 뒤집기(Reverse Order) 기법
 - 입력 시퀀스를 반대로 뒤집어 인코더에 투입하는 등 단순한 전처리 기법이 모델 성능에 의미 있는 향상을 가져올 수 있음을 보였다.

Introduction




Figure 1: Our model reads an input sentence “ABC” and produces “WXYZ” as the output sentence. The model stops making predictions after outputting the end-of-sentence token. Note that the LSTM reads the input sentence in reverse, because doing so introduces many short term dependencies in the data that make the optimization problem much easier.

1. 기존 접근법의 한계 지적

- 전통적인 통계적 기계 번역이나 특수화된 시스템들은 복잡한 구조와 세부적인 설계가 필요했다.
- 학습 과정이 분산되어 있고, 단일 모델이 전체 시퀀스 변환 과정을 학습하기 어려웠다.

2. 뉴럴 네트워크를 활용한 시퀀스 학습의 장점

- 딥러닝이 음성 인식, 이미지 인식 등 여러 분야에서 두각을 나타냄에 따라, 시퀀스 간 변환도 뉴럴 네트워크를 활용해 단일 모델로 처리할 수 있다는 아이디어가 부상했다.
- 큰 규모의 신경망으로 풍부한 표현 학습이 가능하며, 설계·도메인 지식에 대한 의존도를 줄일 수 있다.

3. 제안된 접근(Seq2Seq 모델) 개요

- 인코더-디코더 구조: 하나의 RNN(LSTM)이 입력 시퀀스를 요약(인코딩)하고, 다른 RNN(LSTM)이 그 요약 벡터를 토대로 새로운 시퀀스(번역 결과 등)를 생성(디코딩)한다.
- 이로써 순차 데이터(문장 등)를 엔드-투-엔드 학습 가능하다는 점을 강조한다.

4. 모델 설계와 개선 아이디어

- 긴 시퀀스를 처리할 때 입력 토큰 순서를 뒤집어 인코더에 투입하면, 모델이 학습하기 더 쉬워진다는 점을 발견했다.
- 이 단순한 전처리 기법이 수렴 속도 및 성능 향상에 유의미한 영향을 준다.

5. 연구 의의와 전망

- 엔드-투-엔드로 학습되는 뉴럴 네트워크가 전통적인 통계적 방법론과 경쟁하거나, 더 나은 성능을 낼 수 있음을 시사한다.
- 앞으로 확장된 형태의 RNN, 강화된 사전 훈련 기법 등을 통해 더 다양한 시퀀스 변환 문제에 적용 가능성을 암시한다.

The model

1. 인코더(Encoder)

- 입력 시퀀스($x_1, x_2, \dots, x_T$)를 LSTM으로 처리해, 마지막 타임스텝에서의 은닉 상태(hidden state)를 얻는다.
- 이 은닉 상태는 입력 문장의 전체 정보를 압축한 ‘생각 벡터(thought vector)’로 간주된다.
- 학습 과정에서, 입력 시퀀스를 뒤집어서 인코더에 투입하면, 모델이 더 쉽게 문장 구조를 학습할 수 있다는 개선점을 보여준다.

2. 디코더(Decoder)

- 디코더 역시 LSTM으로 구성되며, 인코더의 최종 은닉 상태를 초기 상태로 받아 출력 시퀀스(y)를 생성한다.
- 각 디코더 스텝에서는 이전에 생성된 토큰(또는 실제 정답 토큰, 학습 시에는 교사 강제(teacher forcing) 사용 가능)와 디코더의 직전 은닉 상태를 입력으로 받아, 다음 단어의 확률 분포를 계산한다.

3. 멀티 레이어(Multi-layer) LSTM

- 인코더와 디코더에 각각 여러 층을 쌓아 표현력을 높일 수 있음을 설명한다.
- 단일 LSTM보다 깊은 네트워크가 언어 표현을 더 풍부하게 학습할 수 있다는 점을 보여준다.

4. 출력 및 학습

- 디코더에서 추론된 각 타임스텝의 출력 벡터는 소프트맥스(softmax) 계층을 통해 단어 분포로 변환되고, 크로스 엔트로피 기반의 손실 함수를 최소화하며 학습된다.
- 인코더-디코더 전체는 엔드-투-엔드 방식으로 공동 학습된다.

Experiment

- 실험 환경 및 데이터
 - WMT'14 영어→프랑스어 데이터셋을 활용하고, 학습을 위한 대규모 텍스트 코퍼스(예: 12M 문장 쌍 수준)를 사용했다.
 - 모델은 LSTM으로 구성된 인코더와 디코더를 가지고 있으며, 여러 층(multi-layer)을 쌓아서 성능을 높일 수 있도록 했다.
- 사전 처리 및 학습 세팅
 - 입력 시퀀스를 뒤집어서(reverse) 인코더에 넣는 기법을 적용해, 시퀀스 길이가 길어져도 학습 안정성을 높였다.
 - SGD(확률적 경사 하강법) 기반 최적화를 사용했으며, 특정 초깃값, 학습률 스케줄 등에 대한 세부 세팅을 논문에 명시했다.
- 성능 평가 및 결과
 - 기계 번역 품질을 BLEU(Bilingual Evaluation Understudy) 점수로 측정했다.
 - 저자들의 모델이 통계적 기계 번역(SMT) 시스템이나 전통적인 RNN 모델에 비해 경쟁력 있는 결과를 얻었으며, 적절한 규모의 신경망과 대규모 데이터 학습 시 우수한 성능을 보인다고 보고했다.
 - 뒤집은 입력이 없는 모델에 비해, 뒤집은 입력을 사용하는 모델이 더 좋은 성능을 낸다고 밝혔다.
- 분석 및 한계
 - 입력 문장을 하나의 벡터로만 요약하기 때문에, 문장이 매우 길어질 경우 정보 손실이 발생할 수 있다는 점을 지적한다.

Type	Sentence
Our model	Ulrich UNK , membre du conseil d' administration du constructeur automobile Audi , affirme qu' il s' agit d' une pratique courante depuis des années pour que les téléphones portables puissent être collectés avant les réunions du conseil d' administration afin qu' ils ne soient pas utilisés comme appareils d' écoute à distance .
Truth	Ulrich Hackenberg , membre du conseil d' administration du constructeur automobile Audi , déclare que la collecte des téléphones portables avant les réunions du conseil , afin qu' ils ne puissent pas être utilisés comme appareils d' écoute à distance , est une pratique courante depuis des années .
Our model	“ Les téléphones cellulaires , qui sont vraiment une question , non seulement parce qu' ils pourraient potentiellement causer des interférences avec les appareils de navigation , mais nous savons , selon la FCC , qu' ils pourraient interférer avec les tours de téléphone cellulaire lorsqu' ils sont dans l' air ” , dit UNK .
Truth	“ Les téléphones portables sont véritablement un problème , non seulement parce qu' ils pourraient éventuellement créer des interférences avec les instruments de navigation , mais parce que nous savons , d' après la FCC , qu' ils pourraient perturber les antennes-relais de téléphonie mobile s' ils sont utilisés à bord ” , a déclaré Rosenker .
Our model	Avec la crémation , il y a un “ sentiment de violence contre le corps d' un être cher ” , qui sera “ réduit à une pile de cendres ” en très peu de temps au lieu d' un processus de décomposition “ qui accompagnera les étapes du deuil ” .
Truth	Il y a , avec la crémation , “ une violence faite au corps aimé ” , qui va être “ réduit à un tas de cendres ” en très peu de temps , et non après un processus de décomposition , qui “ accompagnerait les phases du deuil ” .

Table 3: A few examples of long translations produced by the LSTM alongside the ground truth translations. The reader can verify that the translations are sensible using Google translate.




Figure 3: The left plot shows the performance of our system as a function of sentence length, where the x-axis corresponds to the test sentences sorted by their length and is marked by the actual sequence lengths. There is no degradation on sentences with less than 35 words, there is only a minor degradation on the longest sentences. The right plot shows the LSTM's performance on sentences with progressively more rare words, where the x-axis corresponds to the test sentences sorted by their "average word frequency rank".

Related work

- 통계적 기계 번역(SMT)과 뉴럴 네트워크의 접목
 - 기존에 통계적 기계 번역과 뉴럴 네트워크를 결합하려는 시도가 여러 차례 있었지만, 주로 **언어 모델** 단계에서만 신경망을 활용하는 식이었다.
 - 즉, 완전 엔드-투-엔드로 시퀀스 간 변환을 학습하기보다는, 기존 SMT 파이프라인에 **뉴럴 네트워크 기반 확률 모델**을 추가하는 방식이 많았다.
- 뉴럴 언어 모델(Neural Language Model)
 - **Bengio** 등의 초기 연구로부터 시작해, 어휘(단어)를 임베딩 벡터로 표현하고 RNN 기반 모델이 문맥 정보에 따라 단어 발생 확률을 추론하는 접근이 발전해왔다.
 - 이 연구들은 큰 어휘 집합과 장기 의존 관계 처리에 대한 문제 제기를 했으며, LSTM과 같은 개선된 RNN 구조가 등장하면서 **긴 문맥을 다루는** 능력을 보완했다.
- RNN Encoder-Decoder 초기 연구
 - 논문에서는 "enc-decoder" 구조가 기존에 이미 여러 형태로 시도되었음을 언급한다. 예컨대, **Cho** 등의 RNN Encoder-Decoder 모델은 주어진 문장을 인코딩한 후, 디코더가 이를 바탕으로 새로운 문장을 생성하는 기계 번역 접근을 제안했다.

- 다만, 저자들의 모델은 **더 큰 규모의 데이터와 더 깊은 LSTM 네트워크**로 실험해 성능을 끌어올린 점에서 차별화된다.
- **딥 러닝 및 LSTM의 활용**
 - **Hochreiter와 Schmidhuber**의 LSTM이 긴 시퀀스의 기울기 소실 문제를 크게 완화함으로써, 뉴럴 네트워크를 시퀀스 처리 문제에 활용하기 쉬워졌다.
 - 깊은 신경망이 영상·음성·언어 분야에서 두각을 나타내면서, “엔드-투-엔드” 기계를 만들려는 시도가 자연스럽게 이어졌다.
- **연결 고리와 공현**
 - 저자들은 이런 흐름을 종합해, **기존 통계적 접근과 초기 RNN 기반 시도에서 얻은 통찰을 발전시켜 완전히 뉴럴 네트워크만으로 시퀀스 간 변환을 수행**하는 모델을 제안했다.
 - 이 연구는 이후 **어텐션(Attention)** 도입으로 이어지는 여러 후속 연구에 기반이 되었으며, 뉴럴 기계 번역(NMT)의 본격적인 확산에 기여했다.

Conclusion

1. 결과 요약

- LSTM 인코더-디코더 구조가 대규모 데이터 학습을 통해 통계적 기계 번역 시스템과 경쟁력 있는 성능을 달성함을 확인했다.
- 간단한 전처리 기법(예: 입력 시퀀스 뒤집기)을 통해, 긴 문장을 더욱 잘 처리할 수 있음을 보였다.

2. 연구 의의

- *완전한 뉴럴 네트워크 방식(엔드-투-엔드)**으로 시퀀스 변환 문제를 해결할 수 있다는 가능성을 입증했다.
- 이는 기존 SMT 파이프라인에서 부분적으로 신경망을 사용하는 방식을 넘어서는 새로운 패러다임이라고 강조했다.

3. 향후 과제와 방향

- 모델이 문맥 정보를 하나의 고정 길이 벡터에 의존하기 때문에, 매우 긴 시퀀스에 대해서는 정보 손실 우려가 존재함을 지적했다.
- 어텐션(Attention) 기법 같은 새로운 접근이 이 한계를 보완할 수 있음을 시사한다.
- 네트워크 구조의 확장, 하이퍼파라미터 튜닝, 더 큰 데이터셋을 활용한 훈련 등으로 모델 성능을 계속 높여갈 수 있다고 보았다.

시사 점과 생각해 볼 만한 점

• 엔드-투-엔드 방식의 중요성

- 이전까지 기계 번역 분야에서는 통계적 접근(SMT)이나 규칙 기반 모델이 주류였고, 신경망을 사용하더라도 주로 언어 모델이나 문장 일부 구성 요소에 국한되어 있었다.
- 본 논문은 입력 → 인코딩 → 디코딩 → 출력의 모든 과정을 단일 뉴럴 네트워크로 통합해 **설계 복잡도를 크게 줄이고**, 모델이 스스로 **시퀀스 변환 규칙을 학습**하도록 했다. 이는 향후 어텐션(Attention) 기법이 결합된 Neural Machine Translation(NMT)과 Transformer 계열 모델들의 원형이 되었다.

• RNN/LSTM 기반 모델의 한계와 개선 여지

- 이 논문은 LSTM의 장점을 살려 **긴 문맥(장기 의존 관계)**을 어느 정도 해결했지만, **입력 전체가 하나의 고정 길이 벡터로 요약되는 구조적 제약**이 남아 있었다.
- 이 한계는 뒤이어 “어텐션” 메커니즘을 도입함으로써 크게 완화되었고, 이후에는 CNN, Transformer 등 다양한 구조가 등장하며 시퀀스 학습 방식을 발전시켰다.

- **단순 전처리 기법(시퀀스 뒤집기)의 효과**

- 입력 시퀀스를 반대로 뒤집어 인코더에 넣는 방법이 예측을 뛰어넘는 성능 향상을 가져왔다. 이는 **모델 학습 과정을 조금만 조정해도** 성능을 향상할 수 있음을 보여주며, 뉴럴 네트워크 기반 기법이 가지는 **유연성**을 다시금 강조했다.

- **대규모 학습 데이터와 모델 규모**

- 통계적 방법과 마찬가지로, **더 큰 코퍼스와 더 깊은 네트워크**가 성능을 개선하는 중요한 요인이 됨을 확인했다. 이 논문은 대규모 데이터셋을 효과적으로 활용할 수 있는 **스케일링 가능성**을 시사했고, 이는 이후 GPT, BERT, T5 등 대규모 모델의 시발점이 되었다.

- **미래적 시사점과 생각해볼 거리**

- **장기 의존 관계 처리**: 단순 인코더-디코더 구조의 정보 압축 문제는 모델 확장(더 깊은 LSTM)이나 어텐션으로 일부 해결되었지만, ****긴 시퀀스(수천 단어 등)****를 다루려면 여전히 메모리·연산 부담이 크다는 도전 과제가 남아 있다.
- **모델 해석력**: RNN/LSTM 모델 내부는 그 동작 원리를 직관적으로 이해하기 쉽지 않다. 어떻게 정보를 압축하고, 어떤 방식으로 문맥을 유지하는지 등에 대한 **모델 해석성** 연구는 아직도 활발하다.
- **다양한 도메인 응용**: 본 논문은 기계 번역에 집중했지만, 음성 인식, 이미지 캡셔닝, 질의응답, 요약 등 “입력 시퀀스를 다른 시퀀스로 변환”하는 많은 문제에 응용 가능성을 보여줬다. 이후 Transformer가 비전, 음성, 멀티모달 분야로 확장된 것과 유사한 흐름이 RNN 기반 모델에서도 시도되었다.