



TCN

이름	홍준기
대학교	동국대학교
학과	산업공학과
날짜	2025년

Abstract

새로운 시간 기반 모델인 TCN을 제안하며, 기존의 LSTM 기반 Recurrent Neural Networks(RNNs)보다 빠르게 학습되면서도 더 나은 성능을 보이고 특징으로는 시간적 컨볼루션 계층 사용에서 액션 분할 및 감지를 수행한다는 특징이 있음

Abstract

1. Introduction

기존 언어 모델 사전 학습 기법
제안 방식(TCN)

2. Temporal Convolutional Networks

2.1. Encoder-Decoder TCN (ED-TCN)

2.2. Dilated TCN

2.3. Implementation Details

2.4. Causal vs. Acausal Prediction

Causal TCN

Acausal TCN

Acausal TCN의 변형

3. Experiments

3.1. 평가 지표 (Metrics)

Segmentation Metrics (행동 분할 지표)

Detection Metrics (행동 탐지 지표)

Segmental F1 Score (F1@k)

3.2. Synthetic Experiments (합성 데이터 실험)

Action Composition (행동 조합)

Long-range Temporal Dependencies

3.3. Dataset

4. Results & Ablation Studies

1. Introduction

기존 언어 모델 사전 학습 기법

- Action Segmentation과 Action Detection은 여러 분야에서 중요성을 가
- 기존 접근 방식은 다음과 같은 문제점을 가지고 있음
 - 슬라이딩 윈도우: 긴 시간 패턴을 잘 포착하지 못함
 - 세그먼트 기반 모델: 액션 간의 관계를 제대로 반영하지 못함
 - 순환 신경망(RNN, LSTM): 해석이 어렵고 긴 시퀀스를 잘 다루지 못함
- TCN은 이런 한계를 보완하고자함

제안 방식(TCN)

- Encoder-Decoder TCN (ED-TCN)
 - 시간적 컨볼루션 +pooling + upsampling 사용
 - 얇은 계층 구조지만, 각 계층에 긴 컨볼루션 필터를 사용한 장기 의존성 학습에 초점
- Dilated TCN
 - Dilated Convolution 사용하여 시간적 컨볼루션, not pooling with skip connection
 - 더 깊은 계층으로 만들었지만, 작은 필터를 사용하여 메모리 효율적

2. Temporal Convolutional Networks

2.1. Encoder-Decoder TCN (ED-TCN)

- 구조

- **Encoder:** 여러 개의 컨볼루션 계층을 쌓고, 각 계층은 활성화 함수(ReLU)와 최대 풀링을 사용함
- **Decoder:** 업샘플링(upsampling)과 컨볼루션을 사용하여 원래 크기로 복원함
- **출력:** 최종적으로 각 프레임에 대한 행동 확률을 예측 (Softmax 사용)

- **Receptive Field (수용 영역)**

- 예측할 때 고려하는 시간 범위를 수식으로 정의:

$$r(d,L)=d(2L-1)+1$$

- 여기서 **d**는 필터 크기, **L**은 계층 수

2.2. Dilated TCN

- 구조

- Wavenet 에서 착안한 모델
- Dilated Convolution 사용: 필터 간격을 늘려서 더 넓은 수용 영역을 확보
- Residual Connection추가
 - Skip Connection

- **Receptive Field**

- Dilated Convolution을 사용하면, 같은 계층 수로 더 넓은 시간 영역을 분석할 수 있음:

$$r(B,L)=B \times 2^L$$

- 여기서 **B**는 블록 수, **L**은 블록 당 계층 수

2.3. Implementation Details

- **Loss Function:** Categorical Cross-Entropy 사용
- **Optimization:** Adam Optimizer 사용
- **Dropout:** 일반적인 dropout이 아니라, 전체 컨볼루션 필터를 드롭하는 방식 적용

2.4. Causal vs. Acausal Prediction

Causal TCN

- 예측 시 **현재까지의 정보만** 사용
 - 실시간 예측시 용이

Acausal TCN

- 예측 시 **미래의 정보까지** 사용
 - 더 높은 정확도를 기대할 수 있지만, 실시간 처리는 어려움

Acausal TCN의 변형

- 기본적인 Dilated TCN의 컨볼루션 수식을 확장하여, 이후 시간까지 포함해 예측하고자 함

3. Experiments

3.1. 평가 지표 (Metrics)

Segmentation Metrics (행동 분할 지표)

- 행동 분할 논문에서는 **프레임 단위** 평가 지표가 많이 사용되며, **Accuracy, Precision, Recall** 등이 일반적
- cf) **Segmental Edit Distance**를 사용하기도 함
 - 이는 행동이 **순서가 바뀌거나 과다 분할(over-segmentation)** 되는 오류를 페널티로 적용하는 방식
- 특정 행동이 여러 개의 짧은 세그먼트로 나누어질 경우, 요약 시스템에서는 바람직하지 않음
- 단순 Accuracy 값이 높더라도, **과다 분할(over-segmentation)** 문제가 발생

Detection Metrics (행동 탐지 지표)

- 대표적으로 **Mean Average Precision (mAP)** 사용

- **mAP@mid**: 특정 행동의 **중앙 지점(midpoint)** 이 실제 행동 구간 안에 있으면 TP
- **mAP@k**: Intersection-over-Union (IoU) 값이 특정 threshold **k** 이상일 때 TP
- mAP의 문제점
 - **confidence score**에 민감하게 작용함.
 - 같은 행동 예측 결과라도 confidence score 계산 방식(평균 vs. 최대)에 따라 **큰 차이**가 발생

Segmental F1 Score (F1@k)

- Segmentation과 Detection 모두에 적합한 새로운 **Segmental F1 Score (F1@k)** 제안
- 특징:
 - **Over-segmentation** 문제를 페널티로 적용
 - 작은 시간 차이(annotator 간 오차)는 페널티를 적용하지 않음
 - 행동 길이가 아닌 행동 개수에 따라 점수가 결정
 - IoU 기준으로만 True/False P판단

3.2. Synthetic Experiments (합성 데이터 실험)

- TCN의 장기 시간 의존성 및 행동 조합 패턴 학습 능력을 테스트하기 위해 두 가지 합성 실험

Action Composition (행동 조합)

- 일반적으로 행동 A가 끝난 후 행동 B가 올 확률이 높음
- **CRF 모델**은 이런 패턴을 **전이 확률(transition model)**로 학습하고, **LSTM**은 내부 상태를 이용해 학습
- 실험:
 - **3가지 상위 행동 (A, B, C)**와 각각의 하위 행동(**A1, A2, A3** 등)을 정의
 - 행동 A는 **A1 → A2 → A3** 순으로 항상 진행되며, 이후 B 또는 C로 전환
 - 단순한 프레임 기반 분류 모델은 이 차이를 구분할 수 없음
- 결과:

- TCN은 정확한 행동 분할을 수행
- 이는 TCN이 행동의 순서적 패턴과 지속 시간(duration) 을 잘 학습할 수 있음을 시사

Long-range Temporal Dependencies

- 행동이 발생하기 수 초 또는 수 분 전 정보가 예측에 중요할 수 있음을 고려
- 실험:
 - 입력 데이터에 시간 지연(phase delay) s 를 적용
 - X_t 의 정보가 실제 정답 Y_t 에서 s 프레임 만큼 뒤로 밀려 있음
- 결과:
 - TCN은 receptive field 내에서는 정확한 예측 가능
 - 하지만, Bi-LSTM은 시간이 지연됨에 따라 성능이 빠르게 하락

3.3. Dataset

- 50 salads, MERL Shopping, GTEA..

4. Results & Ablation Studies

Results

- ED-TCN 은 모든 데이터셋에서 기존 방법보다 우수한 성능을 보임
- Frame-wise Accuracy 는 비슷하지만 F1@k 및 Edit Distance 점수에서 큰 차이 발생
- ED-TCN이 다른 방법보다 Over-segmentation 문제가 적음
- Dilated TCN 은 정확도는 높지만 Over-segmentation 문제 발생
- MERL Shopping 데이터셋에서, Bidirectional LSTM 기반 방법보다 F1 점수가 월등히 높음

Ablation Studies

(1) 활성화 함수 (Activation Functions)

- **Normalized ReLU** is best
- **Gated PixelCNN (GPC)** 도 좋음

(2) Receptive Field 크기 실험

- ED-TCN은 receptive field 44프레임 (약 52초) 일 때 최적 성능
- Dilated TCN은 128 프레임 (B=4, L=5) 일 때 최적 성능

(3) 훈련 속도 비교

- TCN > Bi-LSTM
- ED-TCN: 50 Salads 데이터셋 1min, Bi-LSTM은 30minutes +

5. Conclusions

- 합성 데이터 실험을 통해 TCN이 Composition, **Action durations, time delays**에 강건함을 입증함
- 계층적 컨볼루션 구조를 활용하여 장기 시간 패턴을 효과적으로 학습
- 향후 더 깊은 네트워크 구조, 하이브리드 모델(RNN + TCN 조합), 다양한 데이터셋 적용 등에 대한 추가 연구 필요성을 언급함