



TCN

An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling

저자 : Shaojie Bai, J. Zico Kolter, Vladlen Koltun

발행일 : 2018년 4월

An Empirical Evaluation of Generic Convolutional and Recurrent...

For most deep learning practitioners, sequence modeling is synonymous with recurrent networks. Yet recent results indicate that convolutional architectures can outperform recurrent networks on...

 <https://arxiv.org/abs/1803.01271>



0. Abstract

- 시퀀스 모델링에서 합성곱 신경망(CNN)이 순환 신경망(RNN)보다 더 나은 성능을 보일 수 있음을 검증
- 다양한 벤치마크 실험 결과, 단순한 CNN 구조가 LSTM 등 기존 RNN보다 더 우수한 성능과 긴 효과적 메모리를 보여줌
- 이를 바탕으로 시퀀스 모델링에서 RNN의 전통적인 우위를 재고하고, CNN을 기본 선택지로 고려할 필요가 있음을 제안

1. Introduction

- 시퀀스 모델링은 전통적으로 RNN(LSTM, GRU) 중심으로 연구됨
- 최근 연구에서 CNN 이 오디오 합성, 언어 모델링, 기계 번역에서 RNN보다 우수한 성능을 보임
- CNN과 RNN을 다양한 시퀀스 모델링 과제에서 비교 평가

- 실험 결과, TCN이 RNN보다 성능이 뛰어나고 더 긴 메모리 유지 능력을 가짐

2. Background

- CNN과 시퀀스 모델링
 - CNN은 1980~90년대부터 음성 인식, NLP, 문서 분류 등에 활용됨
 - 최근 기계 번역, 오디오 합성, 언어 모델링 등에서 높은 성능을 기록
- RNN과 시퀀스 모델링
 - RNN은 순차 데이터 처리에 특화된 모델로, LSTM과 GRU가 대표적
 - 언어 모델링, 기계 번역 등에서 성공적으로 활용되었으나 학습이 어렵고 구조적 한계가 존재
- CNN과 RNN 비교 연구 부족
 - RNN 내부 아키텍처 비교 연구는 많지만, CNN과 RNN을 직접 비교한 연구는 부족
 - 최근 CNN이 시퀀스 모델링에서 성과를 보임에 따라, 두 아키텍처를 직접 비교하는 연구가 필요
 - 본 연구에서는 CNN과 RNN을 동일한 시퀀스 모델링 과제에서 비교 평가

3. Temporal Convolutional Networks

CNN을 활용한 시퀀스 예측 모델을 제안하며, 이를 Temporal Convolutional Network (TCN) 이라고 명명

TCN은 새로운 개념이 아닌, 시퀀스 모델링에 적합한 CNN 구조를 단순하고 효과적으로 설계한 아키텍처

TCN의 특징

1. 인과적(causal) 합성곱: 미래 정보가 과거로 누출되지 않도록 설계됨
2. 입출력 시퀀스 길이 유지: RNN처럼 입력 시퀀스 길이와 동일한 길이의 출력 생성 가능
3. 긴 메모리 유지:
 - 딥 네트워크 + 잔차 연결(residual layers) 활용

- 확장된 합성곱(dilated convolutions) 을 통해 먼 과거의 정보까지 학습 가능

기존 모델과의 차이점

- WaveNet보다 구조가 단순하며, 스킵 연결, 컨텍스트 스택킹, 게이트 활성화 등을 사용하지 않음
- 기존 언어 모델(LM)과 비교 시, 게이팅 메커니즘 없이 더 긴 메모리 유지 능력을 가짐

3.1. Sequence Modeling

- 입력 시퀀스 $x_0, x_1, \dots, x_T$ 를 기반으로 각 시점의 출력 $y_0, y_1, \dots, y_T$ 를 예측하는 문제
- 인과적 제약: y_t 를 예측할 때, 미래 입력 $x_{t+1}, \dots, x_T$ 는 사용할 수 없음
- 학습 목표: 예측값과 실제값 간 손실 최소화

3.2. Causal Convolutions

- TCN은 1D Fully-Convolutional Network (FCN) + 인과적 합성곱 으로 구성
- 인과적 합성곱(causal convolutions) 을 적용하여 미래 정보 누출 방지
- 제로 패딩(Zero Padding) 추가로 입력과 출력의 시퀀스 길이를 유지
- 기본 구조의 단점: 긴 과거 정보를 학습하기 위해 네트워크가 지나치게 깊어질 가능성

3.3. Dilated Convolutions

- 확장된 합성곱을 사용하여 수용 영역을 지수적으로 확장
- 확장 계수 d 를 증가시키면 더 먼 과거의 정보를 학습할 수 있음
- 필터 크기 k 와 확장 계수 d 를 조정하여 모델의 기억 범위를 유연하게 설정 가능

3.4. Residual Connections

- 깊은 네트워크 학습을 위해 잔차 연결(residual connections) 사용
- 각 레이어에서 ReLU 활성화 함수, 가중치 정규화, 공간 드롭아웃(Spatial Dropout) 적용
- 입력과 출력 차원이 다를 경우, 1x1 합성곱 을 사용해 차원 일치

3.5. Discussion

- 장점
 - 병렬 처리 가능 → RNN과 달리 모든 시점에서 동시에 연산 가능
 - 유연한 수용 영역 조절 → 필터 크기, 확장 계수를 조절해 다양한 시퀀스 길이 적용 가능
 - 안정적인 그래디언트 흐름 → RNN의 기울기 소실/폭발 문제 없음
 - 메모리 효율적 학습 → RNN보다 학습 시 메모리 사용량이 적음
 - 가변 길이 입력 지원 → RNN처럼 다양한 길이의 시퀀스 처리 가능
- 단점
 - 추론 시 메모리 사용 증가 → 전체 시퀀스를 저장해야 하므로 평가 단계에서 더 많은 메모리 필요
 - 도메인 변경 시 재설정 필요 → 특정 도메인에서 학습된 모델을 다른 도메인에 적용할 때 필터 크기(k)와 확장 계수(d)를 조정해야 함

4. Sequence Modeling Tasks

TCN과 RNN(LSTM, GRU 등)을 비교하기 위해 다양한 시퀀스 모델링 벤치마크 과제를 사용하여 평가함

Synthetic Stress Tests (합성 데이터 기반 테스트)

- Adding Problem: 랜덤 숫자 두 개의 합을 예측하는 문제
- Sequential MNIST & P-MNIST: MNIST 데이터를 시퀀스로 입력하여 숫자 분류 (P-MNIST는 랜덤으로 순서 섞임)
- Copy Memory Task: 주어진 입력 시퀀스에서 처음 10개 값을 기억하고 끝부분에서 다시 출력

Real-World Datasets (실제 데이터 기반 평가)

- JSB Chorales & Nottingham: 다성 음악 모델링 (바흐 코랄 및 포크 음악 데이터셋)
- PennTreebank (PTB): 문자 및 단어 수준 언어 모델링
- WikiText-103: 대규모 위키 문서 기반 언어 모델링

- LAMBADA: 문맥을 고려한 단어 예측 과제 (장거리 의존성 평가)
- text8: 대규모 문자 수준 언어 모델링

평가 결과

- TCN이 대부분의 벤치마크에서 RNN보다 뛰어난 성능을 보임
- 특히 긴 메모리 유지가 필요한 과제에서 우수한 성능을 기록
- 언어 모델링, 음악 모델링에서도 경쟁력 있는 성능을 보임

5. Experiments

5.1. Synopsis of Results

- TCN과 LSTM, GRU, RNN 을 비교
- 동일한 TCN 구조를 사용하며 네트워크 깊이(n)와 커널 크기(k)만 조정
- Adam 옵티마이저(learning rate = 0.002) 및 기울기 클리핑 사용
- RNN 모델은 최적의 하이퍼파라미터 탐색(grid search) 후 실험

5.2. Synthetic Stress Tests

- Adding Problem: TCN이 가장 빠르게 수렴하며 MSE가 거의 0에 수렴
- Sequential MNIST & P-MNIST: TCN이 RNN 대비 높은 정확도와 빠른 수렴을 보임
- Copy Memory Task: TCN은 정답을 정확히 예측하는 반면, RNN은 모든 값을 0으로 예측

5.3. Polyphonic Music and Language Modeling

- 다성 음악 모델링 (JSB Chorales, Nottingham): TCN이 RNN보다 우수한 성능
- 언어 모델링 (PennTreebank, WikiText-103, LAMBADA, text8)
 - 소규모 데이터(PennTreebank): 최적화된 LSTM이 TCN보다 성능이 우수
 - 대규모 데이터(WikiText-103, LAMBADA): TCN이 RNN보다 낮은 perplexity 기록

5.4. Memory Size of TCN and RNNs

- Copy Memory Task 실험에서 TCN은 모든 시퀀스 길이에서 100% 정확도 유지
- LAMBADA 데이터셋 실험에서도 TCN이 RNN보다 우수한 성능
- TCN이 장기 의존성을 더 효과적으로 학습하며, 긴 시퀀스를 다루는 데 강점이 있음

6. Conclusion

- TCN은 인과적 합성곱, 확장 합성곱, 잔차 연결을 결합하여 RNN보다 우수한 성능을 보임
- 실험 결과, TCN이 RNN보다 긴 메모리 유지 능력을 가지며 성능이 더 뛰어남
- RNN의 무한 기억 이론적 장점이 실제로는 효과적이지 않음
- 현재 LSTM 기반 아키텍처는 최적화 기법과 정규화 기법이 발전하며 성능이 향상되었으나, TCN은 이에 대한 연구가 부족한 상태
- 향후 TCN에 대한 추가적인 연구와 최적화 기법 개발이 필요하며, TCN이 시퀀스 모델링의 새로운 기본 접근 방식이 될 가능성이 있음