

Transformer 정리본

24기 정현서

이 문서는 Transformer 모델의 전반적인 개념과 구성 요소, 그리고 기존 순환 신경망 (RNN) 기반 모델이 가진 한계를 극복할 수 있는 혁신적인 설계 방식을 자세하게 설명한다. Transformer는 순수한 attention 메커니즘, 특히 self-attention을 중심으로 설계되어, 입력 시퀀스 내의 모든 단어 간 관계를 효과적으로 포착하면서도 병렬 처리가 가능하도록 한다. 이를 위해 모델은 multi-head attention 구조를 도입하여 서로 다른 부분 공간에서 정보를 동시에 학습하고, 각 단어의 상대적 위치 정보를 보완하기 위해 position encoding을 적용한다. 또한, 레이어 정규화와 residual 연결을 활용하여 학습의 안정성과 깊은 네트워크에서도 효과적인 정보 전달을 보장한다.

문서에서는 Transformer의 인코더와 디코더 구조에 대해서도 심도 있게 다룬다. 인코더는 여러 층의 self-attention과 피드포워드 네트워크로 구성되어 입력 문장의 특성을 추출하며, 디코더는 이 정보를 바탕으로 순차적으로 출력을 생성하는 동시에, 이전 출력 정보를 반영하는 masked self-attention 메커니즘을 포함한다. 더불어, 문서에서는 학습 과정에서의 최적화 전략, 학습률 조정, 드롭아웃 기법 등 다양한 기술적 요소들을 소개하며, 이러한 요소들이 모델의 효율성과 번역, 문장 생성 등의 자연어 처리 작업에서 어떻게 뛰어난 성능을 이끌어내는지 실험 결과와 함께 분석한다. 전반적으로 Transformer 모델이 기존 RNN이나 CNN 기반 모델보다 계산 효율성과 성능 면에서 우수함을 입증하며, 향후 다양한 자연어 처리 분야에서의 응용 가능성을 제시하고 있다.