

1. Transformer 의 핵심 개념

(1) 기존 RNN, LSTM 의 문제점

Transformer 이전에는 RNN 과 LSTM 이 NLP 에서 많이 사용되었지만, 다음과 같은 한계가 있었습니다.

1. 병렬 연산 불가능
 - RNN 은 순차적으로 데이터를 처리하므로 학습 속도가 느림.
 - 문장이 길어질수록 훈련 시간이 증가.
2. 장기 의존성 문제
 - 문장이 길어지면, 초반 단어의 정보를 뒤쪽 단어가 잘 기억하지 못하는 문제가 발생.
3. 기울기 소실(Gradient Vanishing)
 - LSTM 이 등장하면서 완화되었지만, 여전히 긴 문장을 학습하는 데 한계가 있음.

(2) Transformer 의 해결책

- Self-Attention Mechanism: 문장 전체를 한 번에 고려하면서, 단어 간 관계를 효과적으로 학습.
 - 병렬 연산 가능: GPU 를 활용하여 빠른 학습 가능.
 - 더 긴 문맥을 학습 가능: 단어 간 관계를 원거리에서도 유지.
-

2. Transformer 의 구조

Transformer 는 인코더(Encoder)와 디코더(Decoder) 두 개의 주요 블록으로 구성됩니다.

(1) Transformer 전체 구조

(2) Encoder (입력 문장을 처리)

- 인코더는 입력 문장을 여러 개의 인코더 블록(Encoder Block)을 거쳐 변환합니다.
- 각 인코더 블록은 Self-Attention + Feed Forward Network(FFN)로 구성됩니다.
- 인코더 블록은 여러 개 쌓을 수 있으며, 일반적으로 6 개 블록(6-layer Transformer)을 사용합니다.

(3) Decoder (출력 문장을 생성)

- 디코더는 인코더의 출력을 받아서, 출력 문장을 생성합니다.
 - 각 디코더 블록은 Self-Attention + Encoder-Decoder Attention + Feed Forward Network(FFN)로 구성됩니다.
 - 이전 단어들을 기반으로 다음 단어를 예측합니다.
-

3. Transformer 의 주요 구성 요소

(1) Self-Attention (자기 주의 메커니즘)

Transformer 의 핵심 개념으로, 단어 간의 관계를 학습하는 과정입니다.

① Attention Score 계산

각 단어가 문장의 다른 단어들과 얼마나 관련이 있는지 측정하는 과정입니다.

- **입력 문장:**
"The cat sat on the mat"
- 각 단어는 나머지 단어들과의 관계(Attention Score)를 계산하여 학습합니다.
- 예를 들어, "cat"은 "sat"과 높은 관련성이 있지만 "mat"과는 덜 관련이 있음.

② Query, Key, Value 벡터 생성

- Query (Q), Key (K), Value (V) 벡터를 생성하여 연산.
- Attention Score 는 점수 계산 후 Softmax 를 적용하여 가중치 결정.

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

③ Multi-Head Attention

- 단일 Attention 이 아닌 여러 개의 Attention Head 를 사용하여 다양한 관계를 학습.
 - 예: 하나의 Head 는 문법적 관계, 다른 Head 는 의미적 관계 학습.
-

(2) Positional Encoding (위치 정보 추가)

- Transformer 는 문장을 한 번에 처리하므로 단어의 순서를 고려하지 않음.

- 이를 해결하기 위해 위치 정보를 나타내는 벡터(Positional Encoding)를 추가함.

$$PE_{(pos,2i)} = \sin(pos/10000^{2i/d_{model}})$$

$$PE_{(pos,2i+1)} = \cos(pos/10000^{2i/d_{model}})$$

- 위치에 따른 주기적 패턴을 가진 벡터를 더하여, 모델이 단어의 순서를 학습할 수 있도록 함.

(3) Feed Forward Network (FFN)

- Attention 을 거친 출력은 각 단어별로 Feed Forward Network (FFN)을 통과하여 변환됨.
- 비선형 변환을 적용하여 더 강력한 표현력을 가지도록 만듦.

4. Transformer 의 장점

병렬 연산 가능

- RNN 과 달리 모든 단어를 동시에 처리 가능 → 훈련 속도가 빠름.

장기 의존성 문제 해결

- 모든 단어 간 관계를 한 번에 계산하기 때문에, 장거리 관계도 잘 학습 가능.

전이 학습(Transfer Learning) 가능

- BERT, GPT 와 같은 모델이 Transformer 를 기반으로 사전 훈련(pretraining)하여 다양한 NLP 작업에 적용 가능.