



Transformers

이름	홍준기
대학교	동국대학교
학과	산업공학과
날짜	2025년

Abstract

Abstract

1. Introduction

2. Model Architecture

2.1. 인코더-디코더 구조

2.2. 어텐션 메커니즘

2.3. 포인트-와이즈 피드포워드 네트워크

2.4. 위치 인코딩

3. Why Self-attention?

3.1. Self-Attention과 기존 모델 비교

4. Experiments

5. Results

영어-독일어 번역 성능 (WMT 2014 En-De)

영어-프랑스어 번역 성능 (WMT 2014 En-Fr)

영어 구문 분석 (English Constituency Parsing)

전적으로 어텐션 메커니즘만을 활용하는 **Transformer 모델**을 제안한 논문으로 CNN이나 RNN network 구조를 활용하지 않고 포지셔널 인코딩과 셀프 어텐션을 기반으로 작동함을 언급하고 있고 이를 통해 기존 모델 대비 **병렬 연산이 가능해져 학습 속도가 빨라졌고, 기계번역 성능에서 기존보다 우수한 결과를 달성**

1. Introduction

- 대부분의 기존 모델은 **RNN**이나 **CNN**을 기반으로 하며, **인코더-디코더(encoder-decoder)** 구조를 사용함.
- 특히 **RNN 기반 모델**은 입력과 출력 시퀀스의 각 위치를 시간축을 따라 계산하기 때문에 **병렬화가 어렵고 학습 속도가 느림**
 - 두 입력 위치 간의 의존성을 학습하는 데 필요한 연산이 거리에 따라 증가하여 **장거리 의존성 학습이 어려움**
- 이를 반영한 Transformer 구조의 제안

2. Model Architecture

2.1. 인코더-디코더 구조

- 기존 인코더-디코더 구조를 따르지만, 각 레이어가 **어텐션과 포인트-와이즈 피드포워드 네트워크(point-wise feed-forward network)**로만 구성됨

인코더(Encoder):

- 입력 시퀀스를 받아 자기 자신에 대한 어텐션(Self-Attention)과 **포인트-와이즈 피드포워드 네트워크**를 수행
 - 총 **6개 층** 사용

디코더(Decoder):

- 이전에 생성된 출력을 이용해 자기 자신에 대한 Self-Attention을 수행한 후, 인코더 출력을 기반으로 하는 인코더-디코더 어텐션(Encoder-Decoder Attention)을 수행하여 다음 출력을 생성함
 - 디코더 역시 **6개 층**으로 구성됨

2.2. 어텐션 메커니즘

- Transformer에서 핵심이 되는 메커니즘으로, **입력과 출력 시퀀스의 각 요소가 서로 얼마나 중요한지를 학습하는 방법**
- 주요 어텐션 메커니즘:
 - Scaled Dot-Product Attention:
 - Query와 Key 간 내적(dot product)을 수행하고, 이를 키 차원의 제곱근으로 나눈 후 Softmax를 적용하여 가중치를 계산
 - 논문에서는 512차원 단어 임베딩을 사용하여 각 쿼리에 대한 각 키들의 energy값인 attention을 계산가능
 - Multi-Head Attention:
 - 여러 개의 어텐션 헤드(8개)를 사용하여 **다양한 의미적 관계를 동시에 학습하게 하되 서로 다른 부분에 주목하도록 하여 모델 성능 향상**
 - h개의 서로 다른 쿼리 키 value를 생성할 수 있도록함+ concatenate

2.3. 포인트-와이즈 피드포워드 네트워크

- 어텐션을 통해 나온 결과를 feed-forward network에 통과시켜 정보를 더 정제하는 과정이고, Relu 활성화함수를 사용해 모든 토큰에 대해 독립적으로 적용

2.4. 위치 인코딩

- 위치 정보(position)를 직접 학습하지 못하는 Transformer 구조상 입력 시퀀스의 각 단어가 어느 위치에 있는 지를 나타내는 추가적인 벡터를 더하는 과정이 필요함
 - 위치 인코딩은 사인(sin)과 코사인(cos) 함수로 정의되는데, 이를 통해 상대적인 위치 정보를 학습하는데 유리함
 - 입력 시퀀스 길이가 학습 범위를 넘어가도 일반화가 가능하다는 점이 있음

3. Why Self- attention?

3.1. Self-Attention과 기존 모델 비교

- 긴 시퀀스에서는 Self-Attention이 더 효율적
- 병렬화 복잡도: $O(1)$ 모든 단어를 동시에 처리 가능 → 병렬화 매우 유리
- 장거리 의존성 복잡도: $O(1)$ 모든 단어가 한 번에 서로를 참고할 수 있음
 - 셀프 어텐션(Self-Attention)은 연산량이 적고, 병렬화가 가능하며, 장거리 의존성을 더 잘 학습할 수 있음

4. Experiments

- WMT 2014 영어-독일어 데이터셋 (약 450만 개 문장)
- WMT 2014 영어-프랑스어 데이터셋 (약 3600만 개 문장)
 - 배치 크기(batch size): 약 25,000개의 단어
 - Adam 옵티마이저 사용
 - 드롭아웃(Dropout) 사용
 - 레이어 정규화(Layer Normalization)

- 레이블 스무딩(Label Smoothing)

5. Results

영어-독일어 번역 성능 (WMT 2014 En-De)

- Transformer (Big) 모델: BLEU 28.4
 - 기존 최고 성능보다 2 BLEU 이상 개선.

영어-프랑스어 번역 성능 (WMT 2014 En-Fr)

- Transformer (Big) 모델: BLEU 41.0
 - 기존 모델 대비 1/4의 학습 비용

영어 구문 분석 (English Constituency Parsing)

- 기존 최고 성능 모델과 유사한 성능을 달성