



week9

Improving Language Understanding by Generative Pre-Training

저자: Alec Radford, Karthik Narasimhan, Tim Salimans, Ilya Sutskever (OpenAI)

발행: arXiv (2018)

핵심 기여

- 비지도 사전 학습(Pre-training) + 지도 미세 조정(Fine-tuning) 방법을 활용하여 자연어 이해(NLU) 성능을 대폭 향상.
- Transformer 기반 언어 모델(Language Model, LM)을 활용하여 다양한 NLP 작업을 단일 모델로 해결 가능하게 함.
- 기존 SOTA 모델을 12개 태스크 중 9개에서 능가하는 성과를 보임.
- 새로운 입력 변환 기법(Task-specific Input Transformations)을 통해 다양한 작업에 최소한의 변경만으로 적용 가능.

1. Seq2Seq 모델 개요

(1) 기존 문제점

- 대부분의 NLP 태스크는 지도 학습(Supervised Learning)이 필요하지만, 레이블된 데이터가 부족한 경우가 많음.
- 기존 Word Embeddings (e.g., Word2Vec, GloVe)는 단어 수준에서 전이 학습(Transfer Learning)을 제공하지만, 문장 수준에서의 효과적인 전이는 부족함.
- 기존 접근법들은 태스크별 전용 모델 구조를 요구하여 범용성이 떨어짐.

(2) GPT(Generative Pre-Training)의 핵심 아이디어

1. 비지도 사전 학습 (Unsupervised Pre-training)

- 대규모 비지도(Unlabeled) 텍스트 데이터로 언어 모델(Language Model)을 학습.
- Transformer 기반 모델을 사용하여 문맥(Context)을 효과적으로 이해하도록 함.

2. 지도 미세 조정 (Supervised Fine-tuning)

- 특정 NLP 태스크(질문 답변, 감성 분석 등)에 맞춰 사전 학습된 모델을 지도 학습(Supervised Learning)으로 조정.
- 모델 구조를 거의 변경하지 않고도 여러 작업에 적용 가능.

✅ 핵심 아이디어: "사전 학습된 언어 모델을 미세 조정하면, 적은 양의 레이블된 데이터로도 성능이 향상될 것이다!"

2. 모델 구조 및 학습 방법

(1) Transformer 기반 모델

- Transformer 디코더(Decoder) 아키텍처만 사용하여 언어 모델을 구성.
- 기존 LSTM/RNN보다 긴 문맥을 학습 가능하며, 병렬 처리가 가능하여 학습 속도 향상.

(2) 입력 변환 기법 (Task-specific Input Transformations)

- 다양한 NLP 태스크를 처리하기 위해, 입력을 특정 방식으로 변환하여 하나의 모델로 학습 가능하게 함.
- 예시:
 - 텍스트 분류 (Text Classification): 단순히 문장을 입력으로 사용.
 - 자연어 추론 (Textual Entailment): 전제(Premise)와 가설(Hypothesis)을 하나의 문장으로 연결.
 - 질문 답변 (Question Answering): 문맥(Context), 질문(Question), 정답 후보(Answer)를 하나의 시퀀스로 변환.

3. 실험 및 결과

(1) 평가 데이터셋

다양한 NLP 태스크에서 성능을 평가함.

태스크 유형	데이터셋
자연어 추론(NLI)	SNLI, MultiNLI, QNLI, RTE, SciTail
질문 답변(QA)	RACE, Story Cloze Test
문장 유사도	MRPC, QQP, STS-B
문서 분류	SST-2, CoLA

(2) 주요 결과

- 기존 최첨단(SOTA) 모델보다 9개 작업에서 성능을 증가!
- 특히 문맥 이해가 중요한 태스크에서 뛰어난 성능을 보임.

📊 주요 성과:

태스크	기존 SOTA 대비 성능 향상
자연어 추론(NLI)	최대 5.8% 개선
질문 답변(QA)	5.7% 개선
상식적 추론(Story Cloze)	8.9% 개선
문장 유사도(STS-B)	1.5% 개선
문서 분류(CoLA)	10% 이상 개선

✓ 결론: "범용적인 하나의 모델로 다양한 NLP 작업에서 높은 성능을 달성할 수 있다."

4. 기술적 분석

(1) 사전 학습의 효과

- 사전 학습 없이 학습한 경우, 성능이 급격히 하락 → 즉, 사전 학습이 필수적임을 증명.
- Transformer 구조가 LSTM보다 긴 문맥을 더 효과적으로 활용할 수 있음.

(2) Zero-shot Learning (사전 학습만으로 성능 평가)

- 모델이 훈련되지 않은 새로운 태스크에서도 일정 수준 이상의 성능을 보임.
- "GPT는 단순한 언어 모델이 아니라, 일반적인 문맥 이해 능력을 학습한다!"

(3) Ablation Study (구성 요소 분석)

- Transformer를 사용하지 않고 LSTM으로 대체하면 성능 하락.
 - 입력 변환 기법이 없으면 성능 저하.
-

5. 결론 및 향후 연구 방향

- 비지도 사전 학습 + 지도 미세 조정 전략이 다양한 NLP 태스크에서 효과적임을 입증.
 - Transformer 기반 사전 학습 모델이 전이 학습(Transfer Learning)에 강력한 효과를 가짐.
 - 이후 연구에서는 "Attention Mechanism을 활용한 더 발전된 모델 (e.g., BERT, GPT-2)"이 등장할 것으로 기대됨.
-

BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding

저자: Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova (Google AI)

발행: arXiv (2018)

1. 핵심 기여

- BERT (Bidirectional Encoder Representations from Transformers)라는 새로운 언어 표현 모델 제안.
 - 기존 단방향 언어 모델(GPT 등)과 달리, 양방향(Bidirectional) 문맥 정보를 활용할 수 있도록 설계.
 - 사전 학습(Pre-training) + 미세 조정(Fine-tuning) 방식으로 다양한 NLP 태스크에서 SOTA(State-of-the-Art) 달성.
 - 11개 자연어 처리(NLP) 태스크에서 기존 모델 대비 대폭 향상된 성능을 보임.
-

2. 기존 문제점

- 기존 ELMo(Peters et al., 2018)는 좌→우(LTR) 및 우→좌(RTL) 두 개의 모델을 별도로 학습해야 함.
- 기존 GPT (Generative Pre-trained Transformer)(Radford et al., 2018)는 단방향(Left-to-Right) Transformer를 사용하여 문맥을 온전히 활용하지 못함.
- 이러한 문제를 해결하기 위해 BERT는 Transformer의 양방향(Bidirectional) 학습 기법을 도입.

3. BERT 모델 개요

(1) 핵심 아이디어

- **양방향 문맥 학습**: 기존 단방향 언어 모델이 아닌, 문장의 좌-우 양방향(Bidirectional Context)을 동시에 학습.
- **두 가지 새로운 사전 학습 기법 도입**:
 1. **Masked Language Model (MLM)**: 입력 문장에서 일부 단어를 [MASK]로 가리고, 모델이 이를 예측하도록 학습.
 2. **Next Sentence Prediction (NSP)**: 두 개의 문장이 실제 연속된 문장인지 예측하는 태스크.

(2) 모델 구조

- Transformer 인코더(Encoder) 아키텍처 사용 (Vaswani et al., 2017).
- 사전 학습된 모델은 다양한 NLP 태스크에 맞춰 미세 조정(Fine-tuning)이 가능.

4. BERT 사전 학습 기법

(1) Masked Language Model (MLM)

- 전통적인 언어 모델은 다음 단어 예측(Next Token Prediction)을 수행하지만, 이는 단방향 학습만 가능.
- BERT는 입력 문장의 15% 단어를 [MASK]로 랜덤하게 가린 후, 해당 단어를 예측하도록 학습.
- 이를 통해 완전한 양방향 문맥을 활용할 수 있음.

(2) Next Sentence Prediction (NSP)

- 문장 간 관계를 학습하기 위해, 두 개의 문장(A, B)을 주고 "B가 A 다음 문장인가?"를 예측.
- 50% 확률로 실제 문장 쌍(IsNext), 나머지 50%는 랜덤 문장 쌍(NotNext)으로 구성.

5. 실험 및 결과

(1) 평가 데이터셋

태스크 유형	데이터셋
자연어 추론(NLI)	MNLI, QNLI, RTE
질문 답변(QA)	SQuAD 1.1, SQuAD 2.0
문장 유사도	MRPC, QQP, STS-B
문서 분류	SST-2, CoLA

상식적 추론	SWAG
--------	------

(2) 주요 결과

- 기존 모델(GPT, ELMo 등) 대비 대부분의 태스크에서 SOTA 달성.
- GLUE 벤치마크에서 7.7%p 향상된 80.5% 달성.
- SQuAD 1.1에서 F1 93.2점, SQuAD 2.0에서 83.1점으로 기존 모델 대비 5.1%p 향상.

 GLUE 벤치마크 결과 (기존 SOTA 대비 성능 향상):

모델	GLUE 점수	MNLI	QNLI	SST-2	CoLA
기존 SOTA	74.0	80.6	82.3	93.2	35.0
GPT	75.1	82.1	87.4	91.3	45.4
BERTBASE	79.6	84.6	90.5	93.5	52.1
BERTLARGE	82.1	86.7	92.7	94.9	60.5

 **결론:** "BERT는 다양한 NLP 작업에서 기존 SOTA 모델을 초월하는 성능을 보인다."

6. 기술적 분석

(1) BERT vs 기존 모델

모델	구조	학습 방식
ELMo	LSTM (좌-우 독립)	Feature-based (문장 임베딩)
GPT	Transformer (단방향)	Fine-tuning (단방향)
BERT	Transformer (양방향)	Fine-tuning (양방향)

- 기존 GPT 모델은 단방향(LTR) Transformer를 사용했지만, BERT는 양방향(Bidirectional) Transformer 사용.
- ELMo는 Feature-based 접근법이지만, BERT는 모델 전체를 미세 조정(Fine-tuning) 가능.

(2) 모델 크기와 성능 관계

- BERT는 모델 크기가 커질수록 성능이 향상됨.
- BERTBASE (110M 파라미터) vs BERTLARGE (340M 파라미터)

(3) Fine-tuning 방식

- BERT는 모든 태스크에서 사전 학습된 모델을 기반으로 미세 조정(Fine-tuning)을 수행.
- 대부분의 NLP 작업에서 태스크별 맞춤형 아키텍처 없이 적용 가능.

7. 결론 및 향후 연구 방향

- 사전 학습 + 미세 조정 접근법이 NLP 모델 성능 향상에 필수적임을 입증.
- BERT의 양방향 문맥 학습(Bidirectional Context Learning)이 기존 단방향 모델보다 우수.

- 이후 연구에서는 더 효율적인 사전 학습 기법(e.g., ALBERT, RoBERTa) 및 경량화 모델 개발이 진행될 것으로 예상.