



week12

Fully Convolutional Networks for Semantic Segmentation

저자: Jonathan Long, Evan Shelhamer, Trevor Darrell (UC Berkeley)

발행: arXiv, 2015

핵심 기여 (Key Contributions)

- 기존 분류용 CNN(AlexNet, VGG, GoogLeNet)을 Fully Convolutional Network (FCN)으로 바꾸어 픽셀 단위의 의미 분할(Semantic Segmentation)에 성공적으로 적용
- 네트워크가 입력 이미지를 그대로 받아서 출력도 동일한 해상도로 예측할 수 있게 함
- 전처리/후처리 없이 end-to-end로 학습 가능
- "skip connection" 구조 도입: 깊은 층(semantic)과 얇은 층(appearance)의 정보를 합쳐 정밀하고 구조적인 예측 가능
- PASCAL VOC, NYUDv2 등에서 SOTA(최첨단) 성능 달성

배경 및 문제의식

Semantic Segmentation이란?

→ 이미지의 각 픽셀마다 어떤 객체(class)에 속하는지 분류하는 작업

(ex. 고양이 그림이면 고양이 영역은 모두 같은 라벨)

기존 문제점

- CNN은 고정된 입력 크기에서 전체 이미지에 대한 클래스만 출력 (즉, 분류용)
- Semantic Segmentation에서는 픽셀마다 결과가 필요, 즉 출력도 dense해야 함
- 기존 방식들은 patch 단위 처리, 복잡한 후처리(superpixel, CRF 등)에 의존

FCN 구조 핵심 아이디어

Fully Convolutional이란?

- 완전히 합성곱(CNN) 레이어만으로 구성된 네트워크
- Fully Connected Layer를 1×1 Convolution으로 변환 → 입력 크기에 상관없이 처리 가능
- 출력도 공간 정보 유지 → 이미지 크기에 따라 유동적인 예측 가능

구성 요소

요소	설명
기존 CNN 변환	AlexNet, VGG16 등의 FC Layer 제거 + Conv로 대체
Upsampling	coarse한 예측을 deconvolution (transpose conv)으로 원래 해상도로 복원
Skip Connection	깊은 층(semantic) + 얇은 층(detail) 결합 → 더 정밀한 예측
Loss Function	Pixel 단위의 Softmax Cross Entropy

FCN 구조의 발전

모델	설명	mean IU
FCN-32s	VGG16 기반, stride 32에서 바로 upsample	59.4
FCN-16s	pool4와 conv7 결합 (stride 16) → 더 세밀	62.4
FCN-8s	pool3까지 추가 결합 (stride 8) → 최고 성능	62.7

점점 더 많은 fine layer를 결합할수록, segmentation이 더 정밀해짐!

실험 결과 요약

PASCAL VOC 2011 & 2012

모델	mean IU	시간
R-CNN	47.9	느림
SDS	52.6	약 50초
FCN-8s	62.7	0.17초 (초고속)

NYUDv2 (RGB-D 이미지)

입력 종류	mean IU
RGB Only	29.2
RGB + Depth(HHA)	34.0

SIFT Flow

- Scene 분할 + Geometry 분할 동시 수행 → 멀티태스킹 구조 적용
- 성능 우수 + 속도 효율적

기술적 디테일 & 트릭

Upsampling (Deconvolution)

- coarse feature를 이미지 크기로 다시 키움

- bilinear로 초기화하고 학습 가능함

Patchwise Training vs Full Image

- 이전엔 patch 단위 학습 → 비효율
- FCN은 전체 이미지를 한 번에 학습 → 더 빠르고 효과적

Skip Connection

- 얇은 층(pool3, pool4 등)의 fine 정보를 가져와
- 깊은 semantic 정보와 합쳐서 정밀하고 자연스러운 분할 수행

결론 및 의의

- CNN의 분류 능력 → 픽셀 단위 예측까지 확장한 최초의 연구
- 복잡한 후처리 없이도 속도 빠르고 정확도 높음
- 이후 SegNet, U-Net, DeepLab 등 많은 segmentation 모델의 기반이 됨

DeepLabv3+: Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation

저자: Liang-Chieh Chen et al. (Google)

발표: arXiv, 2018

핵심 기여 (Key Contributions)

1. DeepLabv3에 Decoder 구조를 추가해서 object boundary 복원 성능 향상
2. Atrous Spatial Pyramid Pooling (ASPP): 다양한 크기의 receptive field로 다중 스케일 문맥 정보 포착
3. Depthwise Separable Convolution 도입: 연산량 줄이면서 정확도 유지 (Xception 기반)
4. PASCAL VOC 2012 (89.0%), Cityscapes (82.1%)에서 SOTA 달성
5. 구현 코드도 공개됨 (TensorFlow): [GitHub 링크](#)

문제의식

왜 새로운 구조가 필요한가?

- FCN, DeepLabv2/v3는 큰 문맥 정보를 잘 포착하지만, 경계(boundary)가 흐릿함
- 반면 U-Net/SegNet 같은 Encoder-Decoder는 경계 복원은 잘하지만 문맥 정보가 부족

그래서 DeepLabv3의 문맥 정보 + Decoder의 경계 복원력을 결합한 DeepLabv3+를 제안

구조 설명

전체 아키텍처: Encoder + ASPP + Decoder

Encoder (DeepLabv3 기반)

- Backbone: ResNet-101 or Xception
- Atrous Convolution (팽창 합성곱)으로 stride를 없애고 큰 receptive field 확보
- ASPP 모듈: 다양한 atrous rate로 여러 크기의 문맥 정보 수집 (6, 12, 18 등)

Decoder

- 기존 DeepLabv3는 단순히 bilinear upsampling만 사용함 → 디테일 손실
- DeepLabv3+는 다음을 수행:
 1. Encoder 출력 (stride=16)을 4배 업샘플
 2. Low-level feature (Conv2)를 가져와서 채널 줄임 (보통 48)
 3. 둘을 concatenate 후, 3×3 convolution 2회 적용
 4. 마지막에 다시 4배 업샘플해서 원본 해상도 복원

→ 결과적으로 자세한 경계 + 넓은 문맥 정보가 조화롭게 포함된 segmentation 출력 완성

핵심 기술 요소

Atrous Convolution

- 필터 사이에 간격을 두어 더 넓은 receptive field 확보
- stride 없이 해상도 유지하며 깊은 특성 추출

Depthwise Separable Convolution

- 일반 Conv보다 연산량 적음
- Depthwise Conv + Pointwise (1×1) Conv 로 분해
- ASPP와 Decoder 모두 이걸로 구성 → 속도 빠르고 효율적
- → 전체 모델 연산량 최대 40% 감소

Output Stride (OS)

- 입력 크기 : 출력 feature map 크기 비율
 - OS=16: 빠름, 정확도 괜찮음 (기본값)
 - OS=8: 느리지만 정확도 향상
-

실험 및 성능 결과

PASCAL VOC 2012 (21 classes)

- 기존 DeepLabv3: 85.7%
- DeepLabv3+ (Xception + JFT pretrain): 89.0% ← 최고 성능

Cityscapes

- 기존 DeepLabv3보다 1.4~2% 성능 향상
- DeepLabv3+: 82.1% (test)

Trimap 실험 (경계 성능 비교)

- Decoder 추가 → 얇은 경계에서 mIOU 최대 5% 향상

Ablation Study (구조별 성능 분석)

실험 조건	mIOU (%)
Decoder 없이 bilinear upsample	77.2
Decoder 추가 (1x1 + 3x3 conv 2회)	78.8
Depthwise Separable Conv 도입	79.9
Multi-scale + Flip 적용	81.6~84.6

결론

- DeepLabv3+는 “문맥 정보 풍부한 인코더” + “경계 복원력 있는 디코더”를 결합해
→ Semantic Segmentation에서 빠르고 정확한 SOTA 성능 달성
- 특히 Xception + Atrous Separable Conv는 효율성과 성능 모두 확보
- 이후 모델 (DeepLabv3+ → DeepLabv4 등)의 기초 토대가 되는 구조