



week13

Segment Anything (SAM)

저자: Alexander Kirillov et al. (Meta AI Research, FAIR)

발표: arXiv, 2023

핵심 기여 (Key Contributions)

- 새로운 **segmentation task** 정의: "Promptable Segmentation"
- **Segment Anything Model (SAM)** 개발: 포인트, 박스, 텍스트 등 다양한 프롬프트에 대응해 마스크 예측 가능
- 세계 최대 규모의 **segmentation 데이터셋 SA-1B** 구축: 11M 이미지, 1.1B 마스크
- 다양한 task에 대해 **Zero-shot 성능** 확보 (즉, 학습 없이도 적용 가능)
- 공개된 모델 + 코드 + 데이터로 연구 확장 가능

문제 정의: Promptable Segmentation

📌 기존 segmentation의 한계

- 기존 segmentation 모델은 태스크마다 별도 학습 필요
- 학습 데이터 부족한 상황에서는 일반화 어려움

💡 새로운 태스크: 프롬프트 기반 분할 (Promptable Segmentation)

- 프롬프트(예: 점, 박스, 마스크, 텍스트)를 주면 → 그에 해당하는 **객체 마스크**를 출력
- 하나의 프롬프트가 모호할 경우에도 **"유효한" 마스크**를 항상 출력해야 함

비유: "어떤 물건을 가리켰을 때, 최소한 그것 중 하나라도 잘라줄 수 있어야 한다!"

모델 구조: Segment Anything Model (SAM)

SAM은 총 3단계 구성!

모듈	역할
----	----

Image Encoder	ViT-H 기반, 고해상도 이미지 임베딩 생성
Prompt Encoder	점/박스/텍스트/마스크 등 다양한 입력을 처리
Mask Decoder	위의 두 정보를 합쳐 빠르게 마스크 출력 (웹에서도 실시간 가능)

기능 요약

- **모호한 입력** → 여러 개의 마스크 동시에 출력 가능 (최대 3개)
- 각 마스크에 대해 신뢰도 점수(예: IoU 예측값)도 함께 예측함

데이터: SA-1B

 **1.1B 마스크, 11M 이미지로 구성된 세계 최대 segmentation 데이터셋**

수집 방식: "데이터 엔진(Data Engine)"

1. 수동+SAM 보조 (Assisted Manual)
2. 반자동 (Semi-automatic)
3. 완전 자동 (Fully Automatic)
 - 최종적으로 99% 이상의 마스크가 **SAM에 의해 자동 생성됨**
 - 평균적으로 **이미지당 100개 이상의 마스크** 포함
 - 해상도도 매우 높음 (평균 3300×4950 → 1500 픽셀로 다운샘플 제공)

학습 방법

- **MAE(Masked Autoencoder)** 사전학습된 ViT-H 사용
- 다양한 형태의 프롬프트를 시뮬레이션해서 학습
- 손실 함수: **Focal Loss + Dice Loss** 조합
- 한 프롬프트에 대해 **항상 유효한 마스크** 출력하도록 학습

Zero-Shot 실험

SAM은 사전학습만으로도 다양한 태스크에 **제로샷 전이 가능!**

실험 태스크 요약

태스크	설명	성과
Point → Mask	한 점만으로 객체 예측	23개 데이터셋 중 16개에서 SOTA
Edge Detection	마스크 → 에지 추출	학습 안 했는데도 뛰어난 결과
Object Proposal	다중 객체 제안	중간/큰 객체에선 ViTDet보다 좋음

Instance Segmentation	탐지된 박스를 프롬프트로 마스크 생성	Human 평가에서 ViTDet보다 우수
Text-to-Mask	텍스트로 객체 지정 → 마스크 출력	CLIP과 결합해 가능성 입증

Responsible AI 분석

- 지리적·소득 수준 다양성 확보 노력 (유럽, 아시아 비중 ↑)
- 성별, 연령, 피부톤 별로도 성능 편차 분석 → 대부분 유사한 성능
- 다만 저소득 국가 이미지 비중은 여전히 낮음

결론

- SAM은 **Segmentation 분야의 Foundation Model**로서의 가능성 제시
- 다양한 형태의 입력을 통해 **모든 객체에 대해 마스크를 생성할 수 있음**
- 단일 프롬프트 기반으로도 높은 성능 확보 → 다양한 **downstream task**에서 활용 가능

Denoising Diffusion Probabilistic Models (DDPM)

저자: Jonathan Ho, Ajay Jain, Pieter Abbeel (UC Berkeley)

발표: NeurIPS 2020

핵심 기여 (Key Contributions)

1. 기존 확산 모델의 퀄리티를 끌어올려, **GAN보다 더 좋은 이미지 샘플 생성** 달성
2. **Denoising Score Matching + Langevin Dynamics**와 확산 모델 학습이 수학적으로 연결됨을 증명
3. 샘플링을 **점진적(Progressive) 복원 과정**으로 해석함 → 압축 및 오토리그레시브 디코딩과 유사
4. CIFAR-10, LSUN 데이터셋에서 **SOTA에 가까운 Inception Score, FID** 기록

배경 및 직관

📌 핵심 아이디어

데이터를 점점 노이즈로 망가뜨리는 과정(forward)을 만들고,
그걸 거꾸로 복원(reverse)하는 과정을 학습하자!

확산 모델 기본 구조

(1) Forward Process (q)

- 시간 t 가 지날수록 데이터에 점점 **Gaussian** 노이즈를 추가
- 마지막엔 완전한 정규분포 $x_T \sim \mathcal{N}(0, I)$ 로 수렴
- 수식:

$$q(x_t|x_{t-1}) = \mathcal{N}(\sqrt{1 - \beta_t}x_{t-1}, \beta_t I)$$

- 결과: $x_0 \rightarrow x_1 \rightarrow \dots \rightarrow x_T \sim \mathcal{N}(0, I)$

(2) Reverse Process (p)

- 목표: $x_T \rightarrow x_{T-1} \rightarrow \dots \rightarrow x_0$ 복원
- 각 단계도 조건부 **Gaussian**:

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(\mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

학습 방법: 변분 추론 & 목적 함수

- **ELBO (Evidence Lower Bound)** 기반 학습
- 수식 정리하면, 결국 각 **timestep**에서의 **KL divergence**를 최소화하는 방식

$$L = D_{KL}(q(x_T|x_0)||p(x_T)) + \sum_{t=1}^T D_{KL}(q(x_{t-1}|x_t, x_0)||p_\theta(x_{t-1}|x_t)) - \log p_\theta(x_0|x_1)$$

- 학습은 쉽게 말해, "노이즈가 있는 데이터를 원래 상태로 복원하는 방법"을 배우는 것!

파라미터화 방식 (ϵ -예측)

💡 **핵심 트릭**: x_{t-1} 는 원래 이미지와 노이즈로부터 생성 가능

$$x_t = \sqrt{\alpha_t}x_0 + \sqrt{1 - \alpha_t}\epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

그래서 모델이 x_0 를 예측하는 대신, ϵ (노이즈) 자체를 예측하도록 하면

→ 학습이 훨씬 안정적이고 샘플 퀄리티도 높아짐

샘플링 방법

학습된 모델을 사용해서 x_T 부터 점점 denoising

Sampling Algorithm (간단 요약)

```
x_T = Normal(0, 1)
for t in T ... 1:
    ε = model(x_t, t)
    x_{t-1} = 1/√α_t * (x_t - (1 - α_t)/√(1 - α_t) * ε) + σ_t * z # z ~ Normal(0, 1)
```

6 실험 결과 (CIFAR-10 기준)

모델	Inception Score ↑	FID ↓
BigGAN	9.22	14.73
StyleGAN2	10.06	3.26
DDPM (ours)	9.46	3.17

- FID 3.17로 StyleGAN2에 근접
- **Unconditional** 생성인데도 **Conditional** 모델 수준의 퀄리티

7 주요 해석 포인트

DDPM은 어떤 모델인가?

- **Generative Model + Latent Variable Model + 마코프 체인 + Score Matching**
- 실제로는 **Langevin Dynamics** 기반 샘플러와도 수학적으로 동일

Progressive Decompression?

- 샘플링 과정을 점진적 압축 해제(=디코딩) 과정으로 해석 가능
- 즉, 마치 오토리그래시브 디코더처럼 하나씩 정보를 복원하는 구조

결론 요약

- 확산 모델도 GAN 못지않게 **고품질 이미지 생성 가능**
- **안정적 학습, 다양한 응용 가능성** (텍스트-이미지, 오디오 등)
- 이후 발전된 **DDIM, Stable Diffusion** 등의 기초가 된 논문!