

1. Abstract (초록)

핵심 아이디어:

객체 검출을 분류기가 아닌 회귀 문제로 접근하여, 이미지 전체에서 한 번의 신경망 평가로 바운딩 박스와 클래스 확률을 예측합니다.

장점:

단일 네트워크로 엔드투엔드 학습이 가능하며, 실시간(기본 모델 45fps, Fast YOLO는 155fps 이상)으로 동작합니다.

전체 이미지의 컨텍스트를 고려하기 때문에 배경에 대한 오검출이 적고, 다양한 객체 표현을 일반화하는 능력이 뛰어납니다.

단점:

정밀한 객체 위치 추정에서는 기존 방법보다 다소 부족할 수 있습니다.

2. Introduction (서론)

문제 제기:

인간은 이미지를 빠르게 파악하지만, 기존의 객체 검출 시스템은 분류기를 여러 위치와 스케일에 적용하는 복잡한 파이프라인을 사용합니다.

YOLO의 접근법:

객체 검출을 이미지 픽셀에서 직접 바운딩 박스 좌표와 클래스 확률을 예측하는 단일 회귀 문제로 재정의합니다.

주요 이점:

단일 네트워크로 모든 처리를 수행하여, 기존 시스템보다 훨씬 빠른 속도로 동작하고 최적화가 쉽습니다.

3. Unified Detection (통합 검출)

Grid 기반 접근법:

입력 이미지를 $S \times S$ 그리드로 나누고, 각 셀은 B개의 바운딩 박스와 해당 박스의 신뢰도 (Confidence)를 예측합니다.

예측 구성:

각 바운딩 박스는 (x, y, w, h, confidence)를 예측하며, 각 셀은 조건부 클래스 확률 ($\text{Pr}(\text{Class}|\text{Object})$)도 예측합니다.

최종 예측:

테스트 시에는 클래스 확률과 박스의 신뢰도를 곱해 최종 클래스별 확률 점수를 산출합니다.

출력 텐서:

예를 들어, PASCAL VOC 데이터셋에서는 $S=7$, $B=2$, $C=20$ 인 경우 최종 $7 \times 7 \times 30$ 텐서를 출력합니다.

4. Network Design (네트워크 설계)

구조:

기본 YOLO 네트워크는 24개의 컨볼루션 레이어와 2개의 완전 연결(FC) 레이어로 구성됩니다.

GoogLeNet에서 영감을 받았으며, Inception 모듈 대신 1×1 축소 레이어와 3×3 컨볼루션 레이어를 사용합니다.

Fast YOLO:

속도를 극대화하기 위해 컨볼루션 레이어 수를 줄인 경량 모델을 제안합니다.

특징:

네트워크는 전체 이미지의 특징을 추출하며, 후반부에 바운딩 박스와 클래스 예측을 위한 레이어가 배치됩니다.

5. Training (학습)

사전 학습:

ImageNet 데이터셋에서 분류 작업으로 사전 학습한 후, 검출을 위해 네트워크를 확장합니다.

학습 전략:

입력 해상도를 224×224에서 448×448으로 증가시켜 세밀한 검출을 지원합니다.

바운딩 박스 좌표 예측에 대해 제곱근을 취해 작은 박스의 오차가 더 크게 반영되도록 합니다.

손실 함수:

좌표 오차와 클래스 오차, 신뢰도 오차를 조합한 다중 항목 손실 함수를 사용하며, λ_{coord} 와 λ_{noobj} 등의 하이퍼파라미터로 각 항의 가중치를 조절합니다.

학습 파라미터:

배치 사이즈 64, 모멘텀 0.9, 가중치 감쇠 0.0005, 학습률 스케줄 등 세부 사항을 통해 안정적인 학습을 도모합니다.

데이터 증강:

드롭아웃과 이미지의 스케일, 위치, 색상 변화 등 다양한 증강 기법을 사용하여 과적합을 방지합니다.

6. Inference (추론)

추론 과정:

테스트 시에도 한 번의 네트워크 평가로 전체 이미지를 처리해 98개의 바운딩 박스를 예측합니다.

후처리:

겹치는 중복 예측을 제거하기 위해 Non-Maximum Suppression(NMS)을 사용하여 최종 검출 결과를 도출합니다.

장점:

단일 평가만으로 빠른 속도와 간단한 파이프라인을 유지할 수 있습니다.

7. Limitations of YOLO (YOLO의 한계)

공간적 제약:

각 그리드 셀이 두 개의 박스만 예측하고 하나의 클래스만 할당할 수 있어, 근접한 다수의 객체나 작은 객체를 잘 검출하지 못할 수 있습니다.

정밀도 문제:

상대적으로 거친 피처를 사용하기 때문에 작은 객체나 경계가 불분명한 객체의 위치를 정확히 예측하는 데 한계가 있습니다.

손실 함수 문제:

모든 오차(대형 박스와 소형 박스)를 동일하게 취급하여, 작은 박스의 미세한 오차가 과도하게 손실에 반영될 수 있습니다.

8. Comparison to Other Detection Systems (다른 검출 시스템과의 비교)

DPM (Deformable Parts Models):

슬라이딩 윈도우 접근법을 사용하는 DPM과 달리, YOLO는 단일 네트워크로 전체 이미지를 처리하며 속도와 통합성이 우수합니다.

R-CNN:

R-CNN은 선택적 검색(Selective Search)으로 수천 개의 후보 영역을 추출한 후 분류하는 방식인데, YOLO는 훨씬 적은 후보 박스(약 98개)로 실시간 처리가 가능합니다.

Fast/Faster R-CNN, OverFeat, MultiBox 등:

이들 방식은 여러 단계의 파이프라인으로 구성되어 있어 처리 속도가 느리거나 복잡한 반면, YOLO는 단일 통합 네트워크로 간단하고 빠르게 동작합니다.

특징:

YOLO는 전역적 문맥을 고려한 검출 방식을 채택하여, 배경 오검출이 적고 다양한 객체를 동시에 검출하는 데 강점을 보입니다.

4. 실험 요약

YOLO vs 다른 실시간 탐지기: YOLO는 Fast R-CNN보다 빠르고 높은 성능을 보이며, 실시간 탐지에서 가장 빠릅니다. Fast R-CNN은 정확도는 높지만 실시간 성능이 떨어집니다. YOLO는 VOC 2007에서 52.7% mAP를 기록하고, YOLO를 개선한 버전은 63.4%로 성능을 끌어올렸습니다.

VOC 2007 오류 분석: YOLO는 배경 오류가 적지만, 객체 위치를 정확하게 찾는 데 어려움이 있어 로컬라이제이션 오류가 많습니다. 반면, Fast R-CNN은 배경 오류가 많고, 위치 정확도는 높은 편입니다.

YOLO와 Fast R-CNN 결합: YOLO의 예측을 Fast R-CNN의 예측에 적용하면 성능이 크게 향상됩니다. YOLO는 Fast R-CNN에서 발생한 배경 오류를 줄여주며, 이 결합으로 mAP가 3.2% 향상되었습니다.

VOC 2012 결과: VOC 2012에서도 YOLO는 여전히 실시간 탐지에서 높은 성능을 보이며, 최신 모델들과 비교하여 뛰어난 성능을 유지합니다.

결론: YOLO는 빠르고 실시간 탐지에 적합한 모델로, Fast R-CNN과 결합하여 성능을 더욱 향상시킬 수 있습니다.