




YOLO 모델 공부

Improvement of YOLO algorithm



YOLOv1 → YOLO9000 → YOLOv3 → YOLOv4 → YOLOv5 → PP-YOLO

You Only Look Once : Unified, Real-Time Object Detection - 2016년

You Only Look Once : Unified, Real-Time Object Detection

- CNN 기반
- You Only Look Once : 전체 이미지를 보는 횟수가 한번
- Unified : classification와 localization 단계를 단일화
- Real-Time : 속도 개선


<YOLO의 특징>

- 단일 신경망 구조를 사용하기 때문에 구성이 간단하며 빠릅니다.

- 주변 정보까지 학습하므로 이미지 전체를 처리하기 때문에 background error가 낮음
- input file을 받으면 하나의 convolution network가 이미지 내에서 찾고자 하는 객체의 bounding box의 위치 정보, bounding box의 class확률을 동시에 계산합니다.


<알고리즘 정리>

1. input 이미지를 SxS Grid로 분할한다.



⇒ 하나의 바운딩 박스당 나오는 아웃풋이 5개(x, y, h, w, Pc)이고, 각 그리드 셀마다 예측하는 bbox가 B개, 클래스의 수가 C개라고 가정하면 $S \times S(B \times 5 + C)$ 개의 tensor로


2. 위 그림에서 격자 1개에 해당하는 것이 grid 영역 1개이다. 여기서 각각의 grid cell은 B개의 bounding box를 예측하고 그 box에 대한 confidence score를 같이 예측하며 계산합니다.



- confidence score는 얼마나 박스 안에 실제로 object가 존재하는지를 계산한다.
- $P_c = \text{confidence score} = \text{Pr}(\text{object}) \times \text{IOU}$
- IOU : object detector의 정확도를 측정하는데 이용되는 평가 지표 (교집합/합집합)
- 만약 cell에 객체가 존재하지 않을 경우, $\text{Pr}(\text{object})$ 는 0이 되어 confidence score가 0이 되고, 객체가 전부 존재한다면 1이 된다.

3. 예측된 각각의 바운딩 박스는 총 5개의 정보($x, y, w, h, \text{confidence}$)를 가지고 있다. x 와 y 는 바운딩 박스의 중심을 나타내며, grid cell의 경계에 상대적인 값이다. w 와 h 는 전체 이미지에 대한 상대적인 w 와 h 를 계산해준 값이다.
 4. 각각의 grid cell은 바운딩 박스 이외에도 C 개의 conditional class probability를 계산해준다.
 - Pr 은 물체가 bbox 내에 있을 때, grid cell에 있는 object가 i 번째 class에 속할 확률
- ⇒ 최종적으로 예측값은 $S \times S \times (B \times 5 + C)$ 크기의 tensor를 가진다. (논문에서는 $s=7, B=2, C=20$ 으로 $7 \times 7 \times 30$ 크기의 텐서를 가짐)
5. 마지막으로, non-max suppression을 거쳐서 최종 바운딩 박스를 선정한다.
 - 4번까지의 과정을 거쳐 나온 confidence score가 많기 때문에, 그중에 중요한 box만을 남겨야함. 그러기 위해서 사용하면 방법이 NMS이다.

1) Network Design - GoogLeNet



- 주로 사용한 구조는 GoogLeNet 구조
- 총 24개의 conv layer + 2개의 fc layer
 - 20개의 conv layer는 1000-class ImageNet으로 pretrained

- 4개의 conv layer + 2개의 fc-layer를 추가로 붙여서 PASCAL VOC에 대해 fine-tuned
- Conv layer를 많이 쌓으면 연산량이 증가하기 때문에 중간에 1X1 reduction layer를 넣어 연산량을 감소시킴

2) 추가 설명

(1) IOU

- object detector의 정확도를 측정하는데 이용되는 평가 지표
- ground-truth bounding boxes : testing set에서 object의 위치를 라벨링한것
- predicted bbox : model이 출력한 object의 위치 예측값


$$\text{IOU} = \frac{\text{area}}{\text{area1} + \text{area2} - \text{area}}$$

The diagram illustrates the calculation of Intersection over Union (IOU) for two bounding boxes. The top part shows a white Prediction Box (area1) and a white Detection Box (area2) overlapping. The intersection is shaded red and labeled 'area'. The bottom part shows the same boxes shaded blue, with the intersection still red. The formula $\text{IOU} = \frac{\text{area}}{\text{area1} + \text{area2} - \text{area}}$ is written between the two diagrams.

⇒ 교집합 / 합집합

(2) NMS (Non-maximum Suppression)

object detector가 예측한 bounding box 중에서 정확한 bounding box를 선택하도록 하는 기법



1. 하나의 클래스에 대한 bbox 목록에서 가장 높은 점수를 가지고 있는 bbox를 선택하고, 이를 목록에서 제거한다. 그리고 final box에 추가한다.
 2. 선택된 bounding box를 boundinf box 목록에 있는 모든 bounding box와 IOU를 계산하여 비교한다.
 - 이때, IOU가 threshold보다 높으면 bounding box 목록에서 제거한다. (중복된다는 의미니까)
 3. 다시, bounding box 목록에 남아있는 bounding 박스에서 가장 높은 점수를 갖고 있는 것을 선택하고 목록에서 제거한다. 그리고 final box에 추가한다.
 4. 2번 과정을 반복한다.
 5. bounding box에 아무것도 남아있지 않을 때까지 반복한다.
- ⇒ 각각의 클래스에 대해 위 과정을 진행한다.


예시) 4x4 그리드, 각 그리드 셀마다 예측하는 바운딩 박스는 두개, 전체 고려하는 클래스의 개수는 20개로 설정함

Unified Detection


예시) $S = 4, B = 2, C = 20$



Resized image 를
4x4 grid 로 분할



Grid cell 마다 bbox 2개씩 예측



14

1. 리사이즈된 이미지를 4X4 그리드로 분할한다.
2. 한 grid cell마다 bbox를 2개씩 예측한다. 또한, confidence를 계산한다.
3. 각각의 bbox마다 5개의 정보 계산
 - x, y 는 진한 파란 박스의 중심 좌표, w 와 h 는 자체 w 와 h 를 전체 인풋 이미지의 w 와 h 로 나누어서 norm한 값으로 0과 1 사이의 값이다. 박스 내에 물체가 있을 확률인 P_c
4. C개 만큼 Pr계산
 - Pr은 물체가 bbox 내에 있을 때, grid cell에 있는 object가 i번째 class에 속할 확률

⇒ 하나의 바운딩 박스당 나오는 아웃풋이 5개이고, 각 그리드 셀마다 예측하는 bbox가 2개, 클래스의 수가 20개라고 가정했으므로 $5*2+20 = 30$ 이 된다.