



Yolo(You only look once)

이름	홍준기
대학교	동국대학교
학과	산업공학과
날짜	2025년

Abstract

Abstract

1. Introduction

기존 문제 제기

제안 방식(Yolo)

2. Model Architecture

2.1. Unified Detection

2.2. 네트워크 설계 (Network Design)

기본 구조

2.3. Training

2.4. Inference

2.5. Difference & Limitations of Yolo

3. Experiments

3.1. Dataset & Results

PASCAL VOC 2007 실시간 탐지

Results

3.2. Error Analysis

YOLO와 Fast R-CNN을 비교하여 오류
유형별 비율

3.3. Fast R-CNN + YOLO Combination

3.4. Generalizability: Person Detection in artwork

YOLO와 다른 탐지 시스템들을 예술 작품
에서 사람을 탐지하는 두 데이터셋에서 비
교하는 실험

새로운 객체 탐지 방법인

YOLO를 소개함. 이전의 객체 탐지 연구들은 분류기(classifier)를 변형하여 탐지를 수행한 반면, 위 논문은 객체 탐지를 공간적으로 분리된 경계 상자(bounding boxes)와 관련된 클래스 확률(class probabilities)로의 회귀 문제(regression problem)로 정식화로

단일 신경망(neural network)이 전체 이미지를 한 번만 평가하여

경계 상자과 클래스 확률을 직접 예측함. 그 결과, 다른 도메인으로 일반화할 때,

YOLO는 DPM이나 R-CNN 같은 다른 탐지 방법들보다 더 나은 성능을 보임

1. Introduction

기존 문제 제기

- 최근 접근 방식인 **R-CNN**은 먼저 region proposal 방법으로 탐지 후보 박스를 만들고, 이 박스들에 대해 분류기를 적용.
 - 이후에 후처리를 통해 박스를 다듬고 중복 제거하며, 장면의 다른 객체들을 고려해 재 점수를 부여하는데, 이는 각 구성 요소를 따로 훈련시켜야 하므로 최적화가 어렵고, 복잡한 파이프라인을 가지고 있음

제안 방식(Yolo)

- 객체 탐지를 단일 회귀 문제로 재정의
 - 즉, 이미지 픽셀에서 직접 **경계 상자 좌표와 클래스 확률을 예측**(이미지를 한 번만 보고 여러 개의 경계 상자과 그에 대한 클래스 확률을 예측함)
 - 새로운 이미지에 대해 단지 한 번 네트워크를 실행하면 탐지 결과가 나와 속도가 빠
 - 전체 이미지를 한 번에 보기 때문에, 객체의 **컨텍스트 정보**를 학습에 활용할 수 있
 - **정확도 면에서는** 최신 탐지 시스템에 비해 떨어짐
 - 객체를 빠르게 인식할 수 있지만, 특히 **작은 객체의 정확한 위치를 잡는 데 어려움**, 즉 이 **트레이드 오프** 관계를 실험에 언급됨

2. Model Architecture

2.1. Unified Detection

- YOLO는 이미지 전체의 특성을 이용해 **모든 클래스에 대해 여러 개의 경계 상자를 동시에 예측**
- **실시간 속도, 높은 정밀도, end-to-end 학습의 특징을 가짐**
- Model 방법
 1. 입력 이미지를 **$S \times S$ 그리드**로 나눔
 2. 객체 중심이 특정 그리드 셀 안에 들어오면, 그 셀이 그 객체를 예측하게 됨
 3. 각 그리드 셀은 **B개의 경계 상자**와 그에 대한 신뢰도(confidence score)를 예측함
 - 신뢰도는 해당 박스에 객체가 있을 확률과 예측 박스의 정확도를 반영
 - 공식: **$\text{Pr}(\text{Object}) \times \text{IOU}(\text{pred}, \text{truth})$**
 - 객체가 없다면 신뢰도는 0이 되어야 하고, 있다면 IOU와 같게 되는 원리
 4. 각 박스는 다음 5개를 예측: **$x, y, w, h, \text{confidence}$**
 - 각 그리드 셀은 **C개의 클래스 확률**도 예측함
 - 테스트 시에는 클래스 확률 $\times$ 신뢰도를 하여, 박스의 **클래스별 신뢰도**를 구함

2.2. 네트워크 설계 (Network Design)

- YOLO는 **CNN**으로 구현되며, **PASCAL VOC** 데이터셋에서 평가

기본 구조

- 24개의 **convolutional layer**
- 2개의 **fully connected layer**
- GoogLeNet 구조를 참고했지만, **Inception 모듈 대신** 1×1 축소층과 3×3 conv layer 사용
- **Fast YOLO**는 24개 대신 **9개의 conv layer**만 사용하여 속도를 극대화

2.3. Training

사전 학습:

- ImageNet 1000 클래스에서 사전 학습
- 앞 20개 conv layer 사용, 평균 풀링 + FC layer

탐지를 위한 레이어 추가:

- conv 4개 + FC 2개 추가 (무작위 초기화)

입력 크기:

- 224×224 → **448×448**로 증가시켜 더 정밀한 탐지를 유도

최종 출력:

- 클래스 확률 + 경계 상자 좌표

활성화 함수:

- 최종 레이어: 선형(linear)
- 나머지: Leaky ReLU 사용

손실 함수:

- **sum-squared error** 사용

- 큰 박스의 작은 오차보다, 작은 박스의 작은 오차가 더 중요하므로 너비와 높이를 **제곱근**으로 예측
- 각 객체는 하나의 예측자만 담당하도록 하여, **bounding box predictor** 간 **집중 파트 유도**→ 예측기들이 특정 크기, 비율, 클래스에 더 강해짐

2.4. Inference

- 학습과 마찬가지로, 테스트 이미지에 대한 예측도 **한 번의 네트워크 평가만**으로 수행
 - PASCAL VOC 기준으로, YOLO는 이미지당 **98개의 경계 상자**와 각 박스에 대한 **클래스 확률**을 예
- 대부분의 경우, 객체가 속한 그리드 셀이 명확하기 때문에, 객체당 하나의 박스만 예측됨
 - **큰 객체나 셀 경계에 걸친 객체**는 여러 셀에서 예측되는(중복 탐지) 경우는 NMS로 해결할 수 있음

2.5. Difference & Limitations of Yolo

- Limitations
 - YOLO는 공간적 제약(spatial constraints)이 강함
 - 각 셀은 **두 개의 박스만** 예측하고, **하나의 클래스만** 예측하므로
 - 무리지어있는 작은 객체들 처리의 어려움
 - YOLO는 학습 데이터를 기반으로 경계 상자를 예측하여, 비정상적 비율, 구성 가진 객체의 적용이 어려움
 - Downsampling계층 포함에 따른 특성이 다소 일반화되어있고 낮은 해상도일 가능성
→ 주요 오류 원인은 부정확한 위치임
- Differences
 - YOLO vs. Deformable Parts Model (DPM)
 - DPM은 **슬라이딩 윈도우** 방식을 기반으로 하며, 각 구성 요소가 **분리된 파이프라인 vs 하나의 모든 작업이 end to end인 Yolo**
 - YOLO vs. R-CNN

- R-CNN 계열은 **Selective Search**로 후보 박스 생성→CNN으로 특징 추출→**SVM분류 vs 각 셀이 잠재적 박스와 점수를 동시 예측(예측 박스 수의 제한)**
- YOLO vs. Fast/Faster R-CNN
 - Fast R-CNN은 분류 속도는 빠르지만, 여전히 Selective Search에 의존하는 R-CNN과 제안 영역도 신경망으로 예측하지만, 여전히 실시간에는 미치지 못하는 Faster R-CNN
- YOLO vs. Deep MultiBox
 - MultiBox는 CNN으로 영역 예측을 수행하지만, 여전히 **전체 탐지 파이프라인의 일부 vs YOLO는 완전한 단일 탐지 시스템**

3. Experiments

3.1. Dataset & Results

PASCAL VOC 2007 실시간 탐지

- 대부분의 실시간 탐지 연구는 파이프라인을 빠르게 만드는 데 집중
- 하지만 실제로 **30 fps 이상 실시간 속도**를 달성한 시스템은 거의 없음

Results

- YOLO는 가장 빠른 객체 탐지기
 - Fast YOLO: **52.7% mAP**
 - YOLO: **63.4% mAP**
 → 기존 실시간 시스템보다 **2배 이상 정확함**
- Faster R-CNN은 정확도는 높지만
 - 가장 빠른 모델: 18 fps
 - 정확한 모델: 7 fps
 → YOLO보다 여전히 느리거나 부정확

3.2. Error Analysis

YOLO와 Fast R-CNN을 비교하여 오류 유형별 비율

- YOLO는 Localization 오류가 대부분
→ 객체는 잘 찾지만, 위치가 정확하지 않음
- Fast R-CNN은 Background 오류가 많음
→ 객체가 없는 배경을 잘못 예측하는 경우가 13.6%
- YOLO는 Fast R-CNN보다 배경 오탐지 오류가 3배 적음

3.3. Fast R-CNN + YOLO Combination

- Whyt?
 - YOLO는 배경에 대한 오류가 적으므로, Fast R-CNN의 배경 박스를 필터링하는 데 사용 가능
 - R-CNN이 예측한 박스와 YOLO 예측 박스가 유사할 경우, YOLO의 신뢰도와 IOU를 기반으로 점수를 보정
 - Results
 - 이 향상은 단순한 앙상블 효과가 아니라, YOLO가 Fast R-CNN과 다른 방식의 실수를 하기 때문에 성능이 보완
- 상위 proposal만으로도 성능이 괜찮음, NMS 제거해도 크게 떨어지지 않음

3.4. Generalizability: Person Detection in artwork

- 기존 객체 탐지용 학술 데이터셋은 학습과 테스트 데이터를 같은 분포에서 가져오지만 현실 세계에서는 테스트 데이터가 학습 데이터와 다를 가능성이 많음

YOLO와 다른 탐지 시스템들을 예술 작품에서 사람을 탐지하는 두 데이터셋에서 비교하는 실험

- Picasso Dataset
- People-Art Dataset
- Results
 - DPM은 성능이 상대적으로 잘 유지, 객체의 형태와 배치를 고려하는 강한 공간 모델을 가지고 있고, 시작 성능은 낮음

- **YOLO**는 VOC 2007에서 좋은 성능을 보일 뿐 아니라, 예술 작품으로 테스트했을 때도 성능 저하가 가장 적었음. **DPM**처럼 크기, 형태, 위치 관계를 모델링해서 형태와 배치가 유사한 예술 이미지에서도 잘 작동한다고 판단 가능
- **R-CNN**은 VOC 2007에서는 높은 AP를 보였지만, 예술 작품에서는 성능이 급격히 하락, 이는 **Selective Search**가 자연 이미지에 최적화되어 있고, 분류기 단계가 작은 영역만 보고 판단하기 때문이라고 추론

3.5. Real-Time Detection in the Wild

- YOLO를 웹캠에 연결하여 실시간 테스트한 결과, 실시간 성능이 유지됨을 확인
 - 이미지를 개별적으로 처리하지만, 웹캠과 연결되면 움직임이나 외형 변화에도 지속적으로 객체를 탐지하며, 마치 추적 시스템처럼 작동함

4. Conclusion

- YOLO는 단순하고 빠르며, end-to-end 학습이 가능하고, 다양한 객체와 환경에서 일반화가 잘 되는 **혁신적인 객체 탐지기**
- 특히 실시간 성능이 중요한 응용 분야에 적용 가능성이 높음